

# **Непараметрические тесты, критерии согласия, бутстррап**

# План

- Критерий знаков, ранговые критерии

# План

- Критерий знаков, ранговые критерии
- Бутстррап

# План

- Критерий знаков, ранговые критерии
- Бутстррап
- Эмпирическая функция распределения

# План

- Критерий знаков, ранговые критерии
- Бутстррап
- Эмпирическая функция распределения
- Критерии согласия

# Непараметрические критерии

# Непараметрические критерии

- Проверка гипотезы – способ посчитать расстояние

# Непараметрические критерии

- Проверка гипотезы – способ посчитать расстояние
- На прошлой неделе мы обсудили параметрические критерии

# Непараметрические критерии

- Проверка гипотезы – способ посчитать расстояние
- На прошлой неделе мы обсудили параметрические критерии
- Мы предполагали вид распределения и получали критерий

# Непараметрические критерии

- Проверка гипотезы – способ посчитать расстояние
- На прошлой неделе мы обсудили параметрические критерии
- Мы предполагали вид распределения и получали критерий
- Можно считать расстояния без предположений о виде распределения → **непараметрические критерии**

# Непараметрические критерии

- Проверка гипотезы – способ посчитать расстояние
- На прошлой неделе мы обсудили параметрические критерии
- Мы предполагали вид распределения и получали критерий
- Можно считать расстояния без предположений о виде распределения → **непараметрические критерии**
- Помогают тестировать гипотезы в ситуациях, когда распределение нестандартное

# Непараметрические критерии

## Параметрические критерии:

- Нулевая гипотеза формулируется о конкретных параметрах распределения
- Перед проведением теста на выборку накладываем предположения о распределении

# Непараметрические критерии

## Параметрические критерии:

- Нулевая гипотеза формулируется о конкретных параметрах распределения
- Перед проведением теста на выборку накладываем предположения о распределении

## Непараметрические критерии:

- Свойства распределения неизвестны
- Используют только информацию из выборки

# Критерии знаков

# Идея критерия

- Превратим выборку в нули и единицы

# Идея критерия

- Превратим выборку в нули и единицы
- Часть информации о выборке мы теряем

# Идея критерия

- Превратим выборку в нули и единицы
- Часть информации о выборке мы теряем
- Но зато всегда можем воспользоваться биномиальным распределением

# Критерии знаков (одновыборочный)

$X_1, \dots, X_n \sim iid$

$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$

# Критерии знаков (одновыборочный)

$X_1, \dots, X_n \sim iid$

$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$

Критерий для проверки:

$$T = \sum_{i=1}^n [X_i > m_0] \sim Bin(0.5, n)$$

# Критерии знаков (одновыборочный)

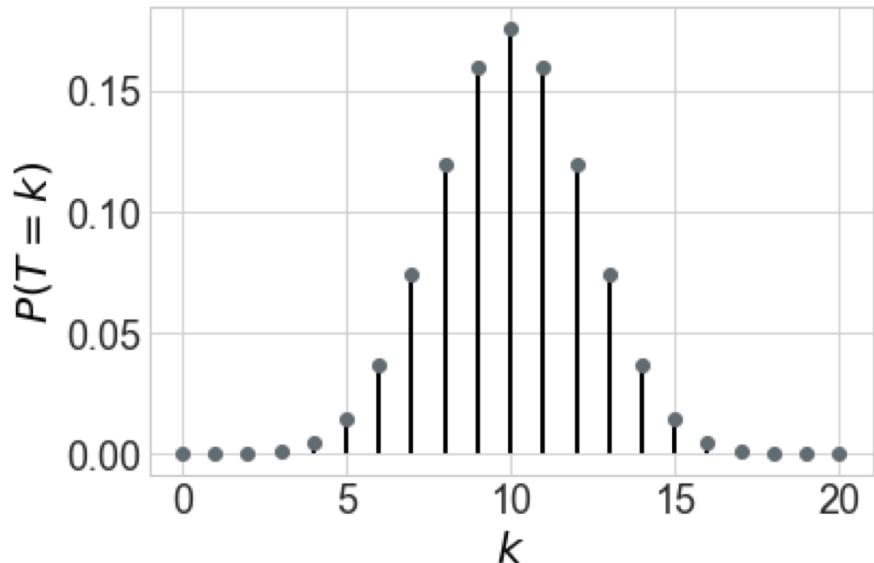
$X_1, \dots, X_n \sim iid$

$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$

Критерий для проверки:

$$T = \sum_{i=1}^n [X_i > m_0] \sim Bin(0.5, n)$$



# Критерии знаков (одновыборочный)

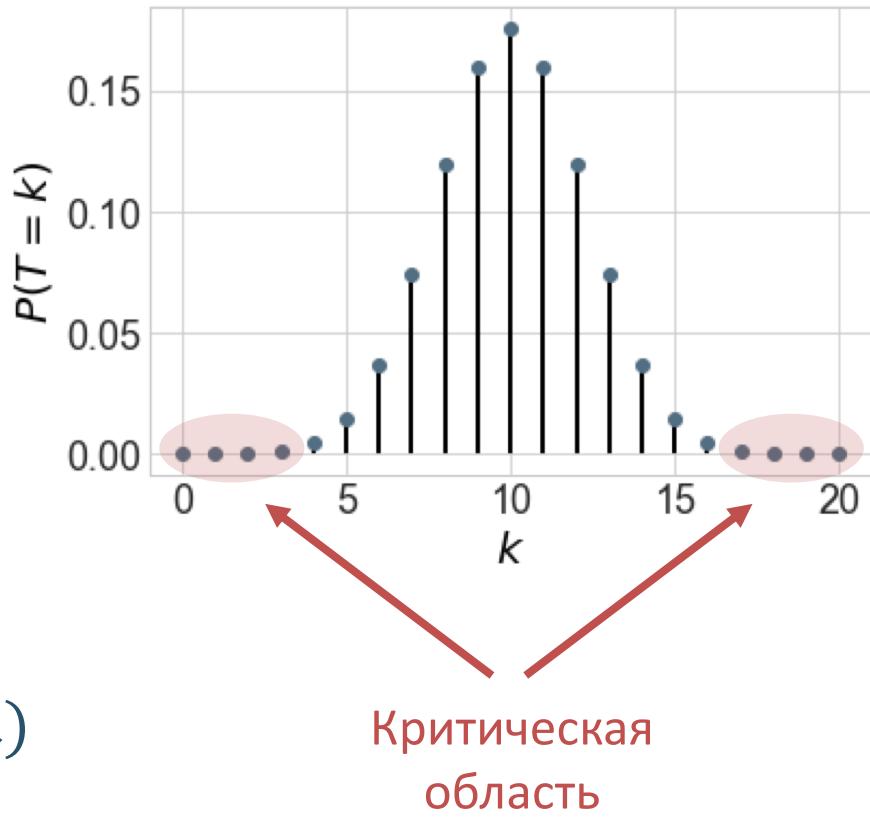
$X_1, \dots, X_n \sim iid$

$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$

Критерий для проверки:

$$T = \sum_{i=1}^n [X_i > m_0] \sim Bin(0.5, n)$$



# Задача о попугаях

**Пример:** есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

# Задача о попугаях

**Пример:** есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

$$H_0: Med(X) = 5$$

$$H_a: Med(X) > 5$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

1, 0, 0, 1, 1

$$H_0: Med(X) = 5$$

$$H_a: Med(X) > 5$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

1, 0, 0, 1, 1

$$T_{\text{набл.}} = 3$$

$$H_0: Med(X) = 5$$

$$H_a: Med(X) > 5$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

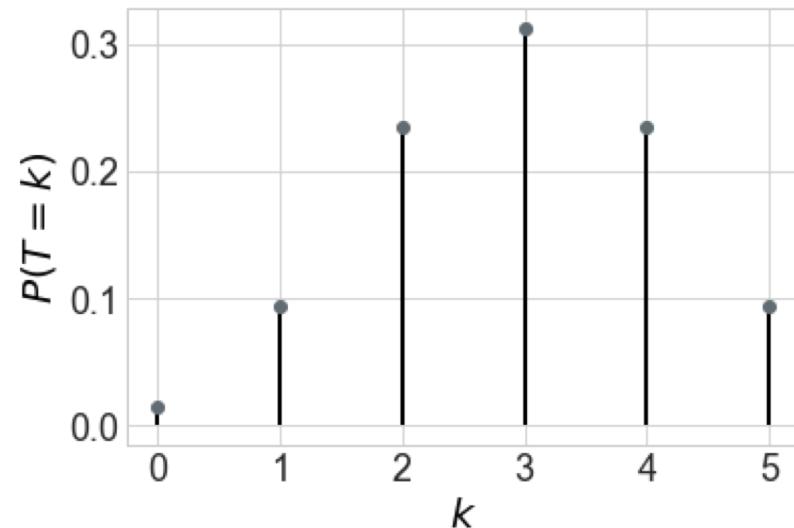
1, 0, 0, 1, 1

$$T_{\text{набл.}} = 3$$

$$H_0: \text{Med}(X) = 5$$

$$H_a: \text{Med}(X) > 5$$

$$\alpha = 0.05$$



# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

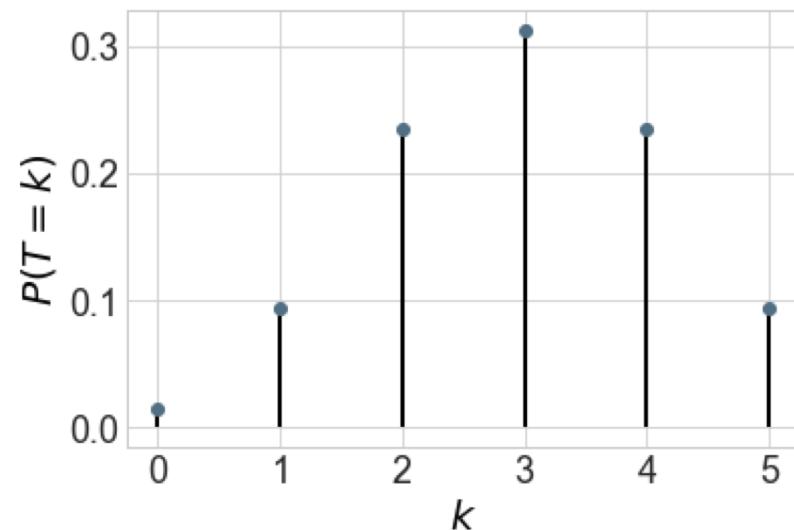
1, 0, 0, 1, 1

$$T_{\text{набл.}} = 3 \quad < \quad T_{\text{кр.}} = T_{1-\alpha} = 5$$

$$H_0: Med(X) = 5$$

$$H_a: Med(X) > 5$$

$$\alpha = 0.05$$



# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

6, 4, 4, 7, 8

1, 0, 0, 1, 1

$$T_{\text{набл.}} = 3 \quad < \quad T_{\text{кр.}} = T_{1-\alpha} = 5$$

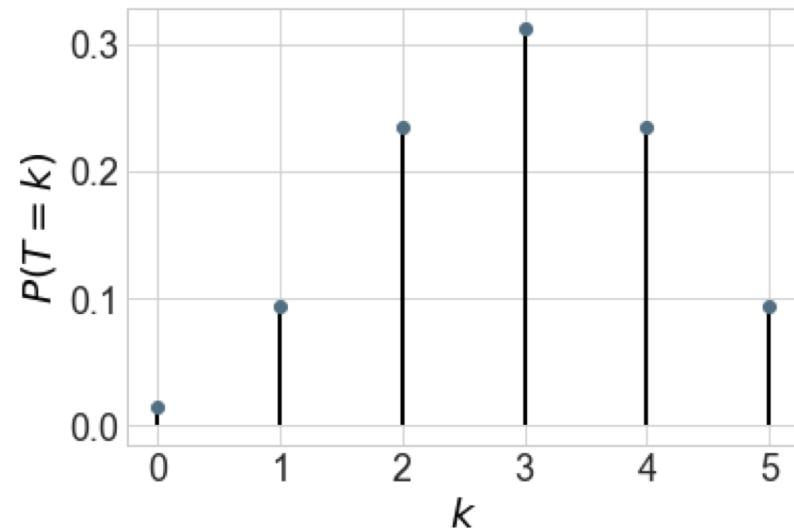
$$H_0: Med(X) = 5$$

$$H_a: Med(X) > 5$$

$$\alpha = 0.05$$



Гипотеза  
не отвергается



# Критерии знаков (двухвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

**Выборки связанные**

# Критерии знаков (двухвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

**Выборки связанные**

! Снова превращаем выборки  
в нули и единицы, но  
немного другим способом

$H_0: \mathbb{P}(X > Y) = 0.5$

$H_a: \mathbb{P}(X > Y) \neq 0.5$

# Критерии знаков (двухвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

Выборки связанные

! Снова превращаем выборки  
в нули и единицы, но  
немного другим способом

$H_0: \mathbb{P}(X > Y) = 0.5$

$H_a: \mathbb{P}(X > Y) \neq 0.5$

Критерий для проверки:

$$T = \sum_{i=1}^n [X_i > Y_i] \sim Bin(0.5, n)$$

# Критерии знаков (двухвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

Выборки связанные

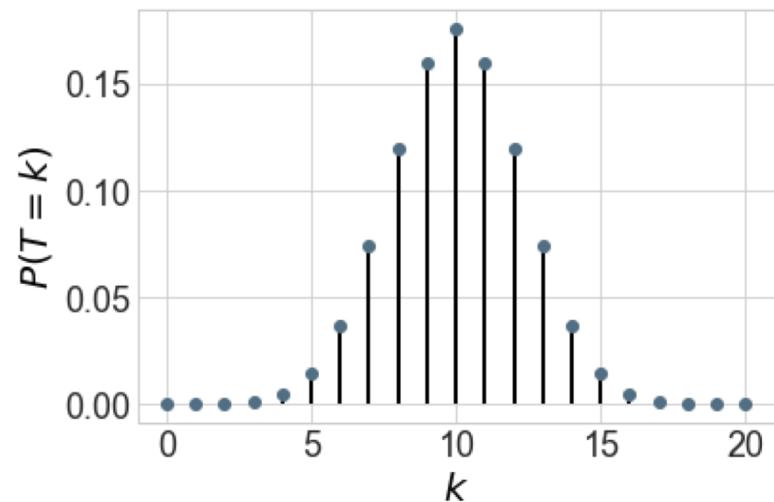
$H_0: \mathbb{P}(X > Y) = 0.5$

$H_a: \mathbb{P}(X > Y) \neq 0.5$

Критерий для проверки:

$$T = \sum_{i=1}^n [X_i > Y_i] \sim Bin(0.5, n)$$

! Снова превращаем выборки в нули и единицы, но немного другим способом



# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60, 58, 60, 70, 81, 87, 60

# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60, 58, 60, 70, 81, 87, 60

$$H_0: \mathbb{P}(X > Y) = 0.5$$

$$H_a: \mathbb{P}(X > Y) > 0.5$$

$$\alpha = 0.05$$

# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60 58, 60, 70, 81, 87, 60  
0 0 0 1 1 1 0 1 1 0

$$H_0: \mathbb{P}(X > Y) = 0.5$$

$$H_a: \mathbb{P}(X > Y) > 0.5$$

$$\alpha = 0.05$$

# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60 58, 60, 70, 81, 87, 60

0 0 0 1 1 1 0 1 1 0

$$T_{\text{набл.}} = 5$$

$$H_0: \mathbb{P}(X > Y) = 0.5$$

$$H_a: \mathbb{P}(X > Y) > 0.5$$

$$\alpha = 0.05$$

# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60 58, 60, 70, 81, 87, 60

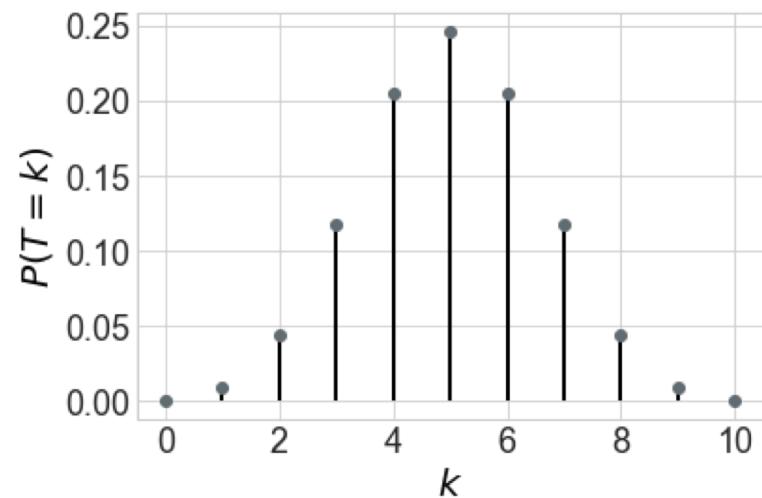
0 0 0 1 1 1 0 1 1 0

$$T_{\text{набл.}} = 5$$

$$H_0: \mathbb{P}(X > Y) = 0.5$$

$$H_a: \mathbb{P}(X > Y) > 0.5$$

$$\alpha = 0.05$$



# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60 58, 60, 70, 81, 87, 60

0 0 0 1 1 1 0 1 1 0

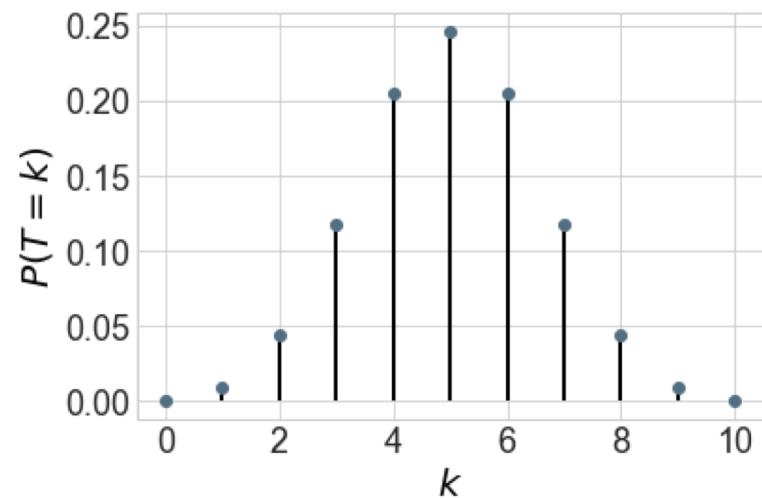
$$T_{\text{набл.}} = 5$$

$$T_{\text{кр.}} = 8$$

$$H_0: \mathbb{P}(X > Y) = 0.5$$

$$H_a: \mathbb{P}(X > Y) > 0.5$$

$$\alpha = 0.05$$



# Задача про апелляцию

Пример: даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

До: 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

После: 47, 52, 60, 60 58, 60, 70, 81, 87, 60

0 0 0 1 1 1 0 1 1 0

$$T_{\text{набл.}} = 5$$

$$T_{\text{кр.}} = 8$$

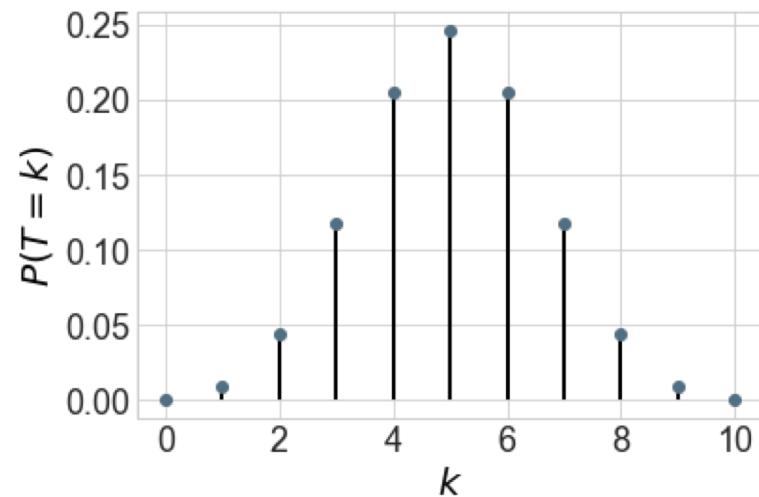
$$H_0: \mathbb{P}(X > Y) = 0.5$$

$$H_a: \mathbb{P}(X > Y) > 0.5$$

$$\alpha = 0.05$$



Гипотеза  
не отвергается



# Резюме

- Критерий знаков позволяет проверять гипотезу о равенстве медианы и отсутствии сдвига в связных выборках

# Резюме

- Критерий знаков позволяет проверять гипотезу о равенстве медианы и отсутствии сдвига в связных выборках
- Критерий знаков игнорирует величину изменений и обращает внимание только на её направление

# Резюме

- Критерий знаков позволяет проверять гипотезу о равенстве медианы и отсутствии сдвига в связных выборках
- Критерий знаков игнорирует величину изменений и обращает внимание только на её направление
- Из-за этого происходит потеря части информации о выборке

# Ранговые критерии

# Идея критерия

- Критерии знаков превращают выборку в нули и единицы, из-за этого теряется информация

# Идея критерия

- Критерии знаков превращают выборку в нули и единицы, из-за этого теряется информация
- Чтобы сохранить больше информации о выборке, можно превращать наблюдения в ранги

# Ранг наблюдения

$x_1, x_2, \dots, x_n$  – выборка

$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$  Упорядочим по возрастанию

# Ранг наблюдения

$x_1, x_2, \dots, x_n$  – выборка

$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$  Упорядочим по возрастанию

## Правила выставления ранга:

1. Порядковый номер наблюдения – ранг
2. Если встречаются несколько одинаковых значений, им присваивается одинаковое значение ранга, равное среднему арифметическому их порядковых номеров

# Критерии Уилкоксона (одновыборочный)

$X_1, \dots, X_n \sim iid$

$F_X(x)$  симметрична  
относительно медианы

# Критерии Уилкоксона (одновыборочный)

$X_1, \dots, X_n \sim iid$

$F_X(x)$  симметрична  
относительно медианы

$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$

# Критерии Уилкоксона (одновыборочный)

$X_1, \dots, X_n \sim iid$

$F_X(x)$  симметрична  
относительно медианы

$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$

Критерий  
для проверки:

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

# Критерии Уилкоксона (одновыборочный)

$X_1, \dots, X_n \sim iid$

$F_X(x)$  симметрична  
относительно медианы

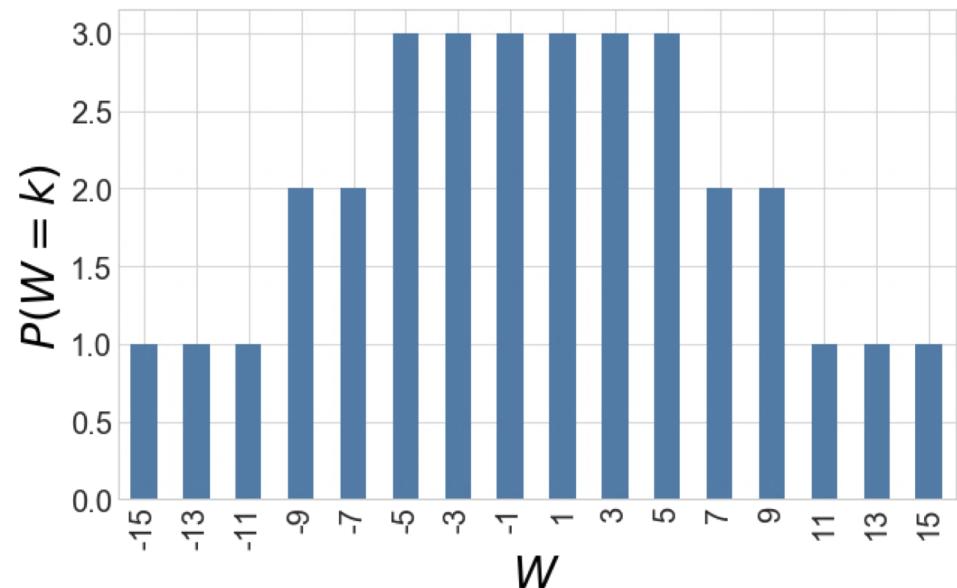
$H_0: Med(X) = m_0$

$H_a: Med(X) \neq m_0$



У статистики табличное  
распределение

Распределение для  $n = 5$



Критерий  
для проверки:

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

# Распределение статистики

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

# Распределение статистики

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

Пусть в выборке пять наблюдений:

# Распределение статистики

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

Пусть в выборке пять наблюдений:

Ранги

1	2	3	4	5

# Распределение статистики

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

Пусть в выборке пять наблюдений:

1	2	3	4	5
—	—	—	—	—
+	—	—	—	—
—	+	—	—	—
...	...	...	...	...
—	+	+	+	+
+	+	+	+	+

Ранги

Знаки

# Распределение статистики

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

Пусть в выборке пять наблюдений:

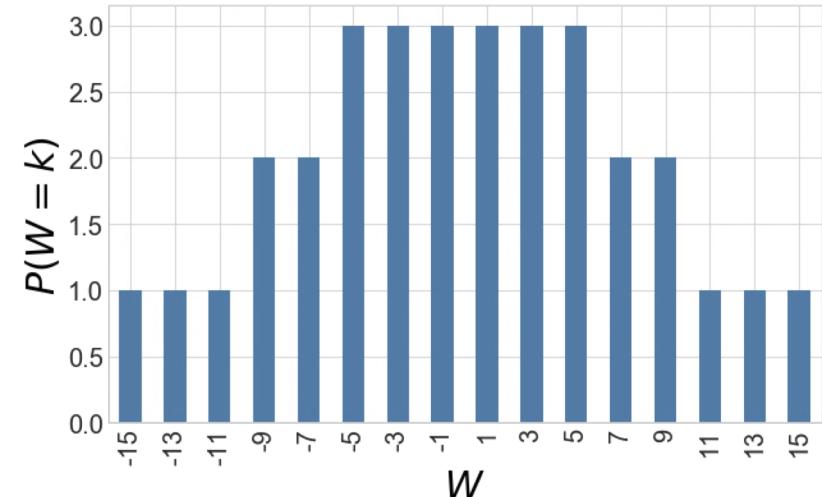
1	2	3	4	5	
—	—	—	—	—	-15
+	—	—	—	—	-13
—	+	—	—	—	-11
...	...	...	...	...	...
—	+	+	+	+	13
+	+	+	+	+	15

# Распределение статистики

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

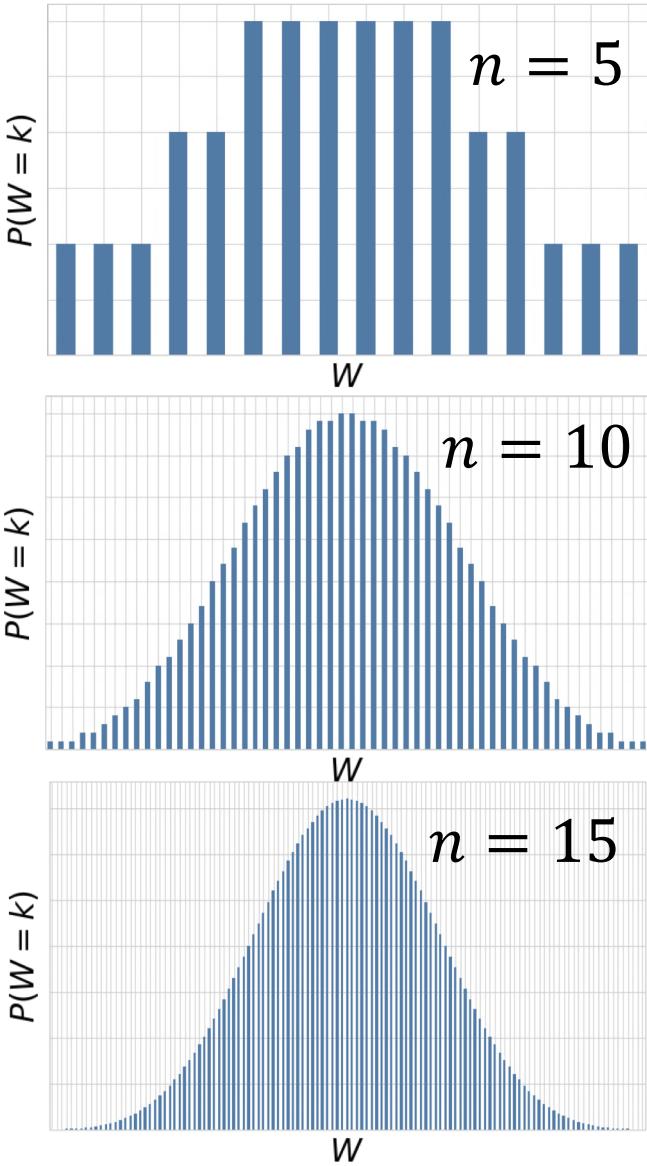
Пусть в выборке пять наблюдений:

1	2	3	4	5	
—	—	—	—	—	-15
+	—	—	—	—	-13
—	+	—	—	—	-11
...	...	...	...	...	...
—	+	+	+	+	13
+	+	+	+	+	15



Всего вариантов:  $2^n$

# Апроксимация



При больших  $n$  пользуются нормальным приближением:

$$W \stackrel{asy}{\sim} N\left(0, \frac{n \cdot (n + 1) \cdot (2n + 1)}{6}\right)$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

$$X_i \quad 6 \quad 4 \quad 4 \quad 7 \quad 8 \qquad m_0 = 5$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорят больше 5 слов?

$$X_i \quad 6 \quad 4 \quad 4 \quad 7 \quad 8 \qquad m_0 = 5$$

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорит больше 5 слов?

$$\begin{array}{ccccccc} X_i & 6 & 4 & 4 & 7 & 8 & m_0 = 5 \\ |X_i - m_0| & 1 & 1 & 1 & 2 & 3 \end{array}$$

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорит больше 5 слов?

$X_i$	6	4	4	7	8	$m_0 = 5$
$ X_i - m_0 $	1	1	1	2	3	
$rank( X_i - m_0 )$	2	2	2	4	5	

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорит больше 5 слов?

$X_i$	6	4	4	7	8	$m_0 = 5$
$ X_i - m_0 $	1	1	1	2	3	
$rank( X_i - m_0 )$	2	2	2	4	5	
$sign(X_i - m_0)$	+	-	-	+	+	

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

$$\alpha = 0.05$$

# Задача о попугаях

Пример: есть данные о говорливости попугаев (слов в день), правда ли, что в среднем попугай говорит больше 5 слов?

$X_i$	6	4	4	7	8	$m_0 = 5$
$ X_i - m_0 $	1	1	1	2	3	
$rank( X_i - m_0 )$	2	2	2	4	5	
$sign(X_i - m_0)$	+	-	-	+	+	

$$\Rightarrow W_{\text{набл.}} = 7 \quad W_{\text{кр.}} = W_{1-\alpha} = 12$$



Гипотеза **не**  
отвергается

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$
$$\alpha = 0.05$$

# Критерии Уилкоксона (двуихвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

**Выборки связанные**

# Критерии Уилкоксона (двуихвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

**Выборки связанные**

$H_0: Med(X - Y) = 0$

$H_a: Med(X - Y) \neq 0$

# Критерии Уилкоксона (двуихвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

**Выборки связанные**

$H_0: Med(X - Y) = 0$

$H_a: Med(X - Y) \neq 0$

**Критерий для проверки:**

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Критерии Уилкоксона (двуихвыборочный)

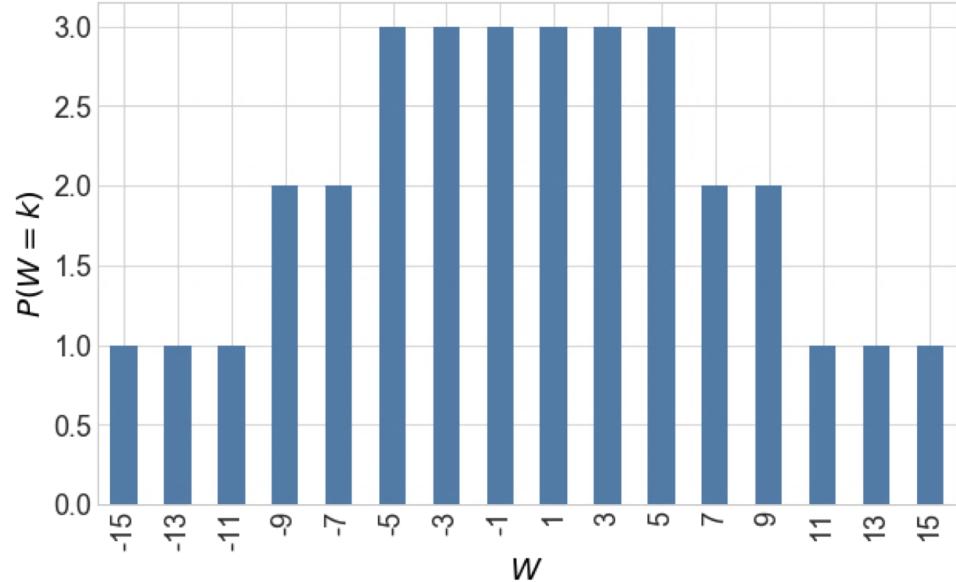
$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

**Выборки связанные**

$H_0: Med(X - Y) = 0$

$H_a: Med(X - Y) \neq 0$



**Критерий для проверки:**

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Критерии Уилкоксона (двуихвыборочный)

$X_1, \dots, X_n \sim iid$

$Y_1, \dots, Y_n \sim iid$

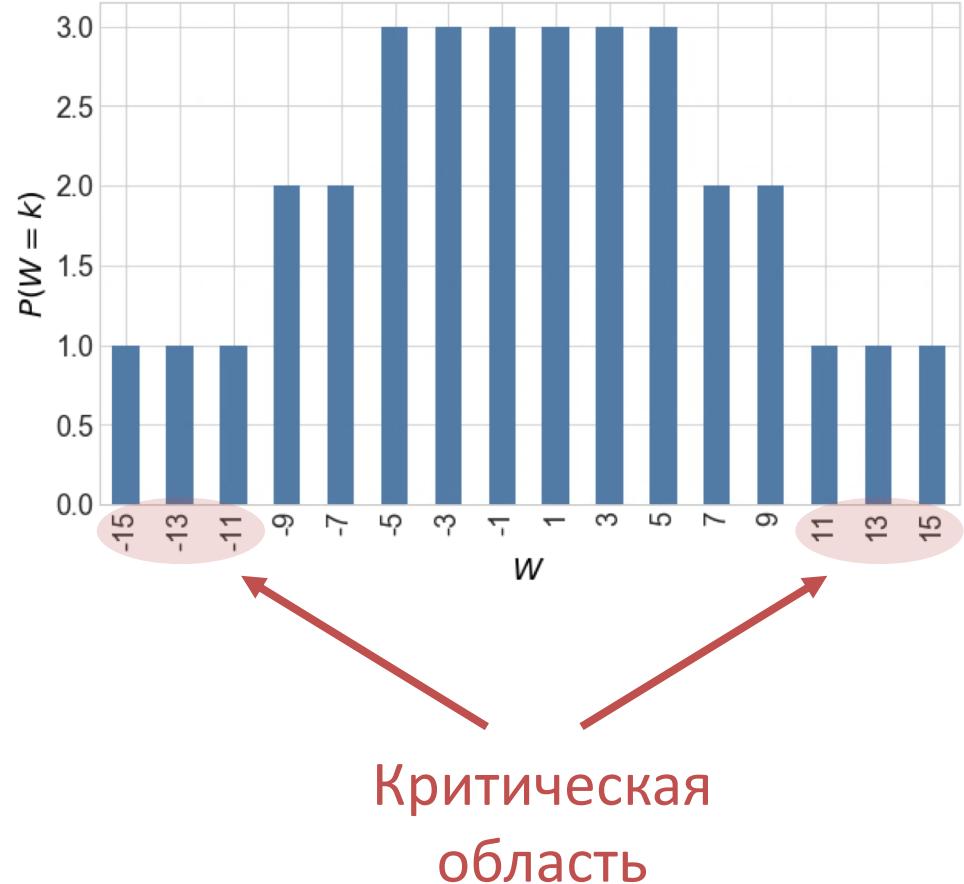
**Выборки связанные**

$H_0: Med(X - Y) = 0$

$H_a: Med(X - Y) \neq 0$

**Критерий для проверки:**

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$



Критическая  
область

# Задача про апелляцию

**Пример:** даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

**До:** 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

**После:** 47, 52, 60, 60 58, 60, 70, 81, 87, 60

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Задача про апелляцию

**Пример:** даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

**До:** 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

**После:** 47, 52, 60, 60 58, 60, 70, 81, 87, 60

$|X_i - Y_i|$  1 2 7 4 3 5 20 10 15 9

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Задача про апелляцию

**Пример:** даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

**До:** 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

**После:** 47, 52, 60, 60 58, 60, 70, 81, 87, 60

$ X_i - Y_i $	1	2	7	4	3	5	20	10	15	9
$rank( X_i - Y_i )$	1	2	6	4	3	5	10	8	9	7

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Задача про апелляцию

**Пример:** даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

**До:** 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

**После:** 47, 52, 60, 60 58, 60, 70, 81, 87, 60

$ X_i - Y_i $	1	2	7	4	3	5	20	10	15	9
$rank( X_i - Y_i )$	1	2	6	4	3	5	10	8	9	7
$sign(X_i - Y_i)$	+	+	+	-	-	-	+	-	-	+

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Задача про апелляцию

**Пример:** даны баллы студентов до и после апелляции.  
Правда ли, что в среднем апелляция не повышает балл  
за контрольную?

**До:** 48, 54, 67, 56, 55, 55, 90, 71, 72, 69

**После:** 47, 52, 60, 60, 58, 60, 70, 81, 87, 60

$ X_i - Y_i $	1	2	7	4	3	5	20	10	15	9
$rank( X_i - Y_i )$	1	2	6	4	3	5	10	8	9	7
$sign(X_i - Y_i)$	+	+	+	-	-	-	+	-	-	+

$$\Rightarrow W_{\text{набл.}} = -3 \quad W_{\text{кр.}} = W_{1-\alpha} = 33$$



Гипотеза  
не отвергается

$$W = \sum_{i=1}^n rank(|X_i - Y_i|) \cdot sign(X_i - Y_i)$$

# Критерии Манна-Уитни (двухвыборочный)

$$X_1, \dots, X_{n_x} \sim iid$$

$$Y_1, \dots, Y_{n_y} \sim iid$$

Выборки независимые

$$n_x \leq n_y$$

# Критерии Манна-Уитни (двуихвыборочный)

$X_1, \dots, X_{n_x} \sim iid$

$Y_1, \dots, Y_{n_y} \sim iid$

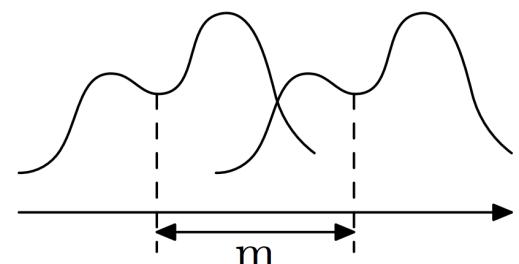
Распределения одинаковые  
по форме, различаются сдвигом

Выборки независимые

$$n_x \leq n_y$$

$$H_0: f_X(x) = f_Y(y)$$

$$H_a: f_X(x) = f_Y(y + m), m \neq 0$$



# Критерии Манна-Уитни (двуихвыборочный)

$$X_1, \dots, X_{n_x} \sim iid$$

$$Y_1, \dots, Y_{n_y} \sim iid$$

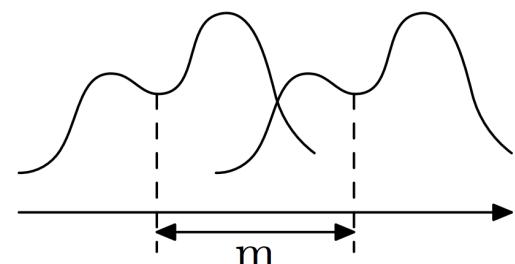
Распределения одинаковые по форме, различаются сдвигом

Выборки независимые

$$n_x \leq n_y$$

$$H_0: f_X(x) = f_Y(y)$$

$$H_a: f_X(x) = f_Y(y + m), m \neq 0$$



Объединим обе выборки в одну общую и посчитаем для всех чисел ранги

Критерий для проверки:

$$W = \sum_{i=1}^{n_x} rank(X_i)$$

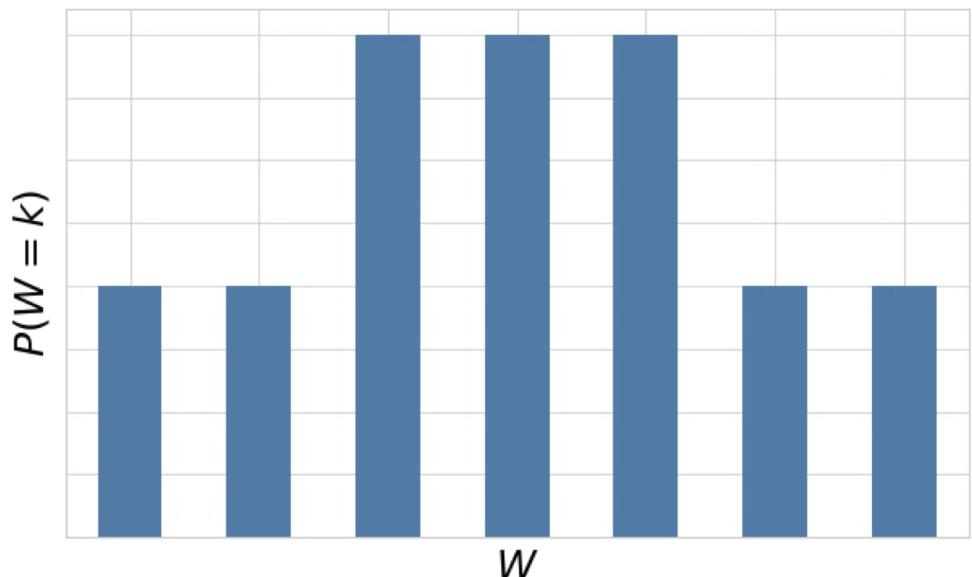
# Критерии Манна-Уитни (двуихвыборочный)

$rank(X)$	$rank(Y)$
{1, 2}	{3, 4, 5}
{1, 3}	{2, 4, 5}
{1, 4}	{2, 3, 5}
{1, 5}	{2, 3, 4}
{2, 3}	{1, 4, 5}
...	...

# Критерии Манна-Уитни (двуихвыборочный)

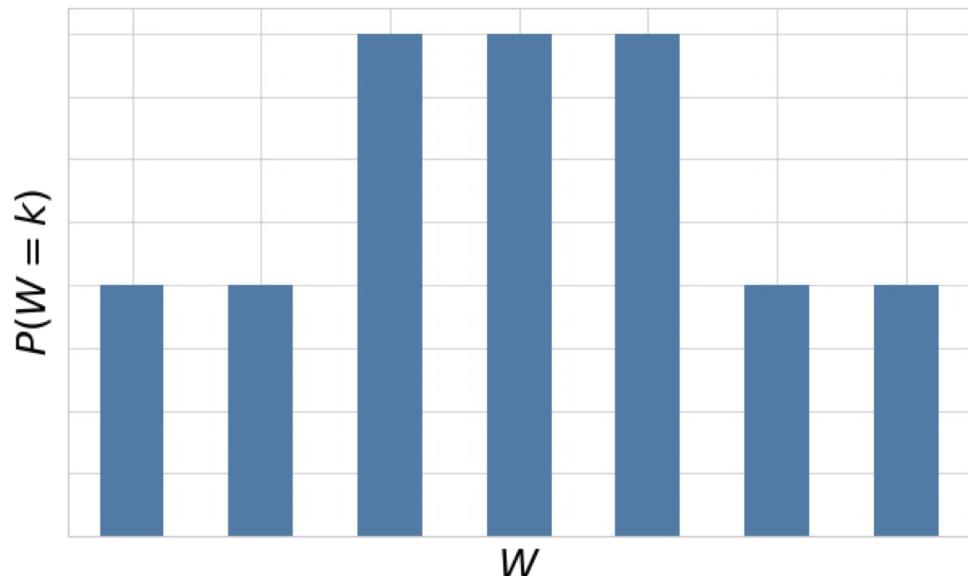
$rank(X)$	$rank(Y)$
$\{1, 2\}$	$\{3, 4, 5\}$
$\{1, 3\}$	$\{2, 4, 5\}$
$\{1, 4\}$	$\{2, 3, 5\}$
$\{1, 5\}$	$\{2, 3, 4\}$
$\{2, 3\}$	$\{1, 4, 5\}$
...	...

Всего  $C_{n_x+n_y}^{n_x}$  вариантов



# Критерии Манна-Уитни (двуихвыборочный)

$rank(X)$	$rank(Y)$
$\{1, 2\}$	$\{3, 4, 5\}$
$\{1, 3\}$	$\{2, 4, 5\}$
$\{1, 4\}$	$\{2, 3, 5\}$
$\{1, 5\}$	$\{2, 3, 4\}$
$\{2, 3\}$	$\{1, 4, 5\}$
...	...



Всего  $C_{n_x+n_y}^{n_x}$  вариантов

- Распределение статистики снова оказывается табличным
- Для больших объёмов выборки можно использовать нормальное приближение

# Задача про кофе

**Пример:** две группы людей принимают препарат перед забегом на сто метров

**Кофеин:** 12, 10

**Плацебо:** 13, 11, 14

# Задача про кофе

**Пример:** две группы людей принимают препарат перед забегом на сто метров

**Кофеин:** 12, 10

**Плацебо:** 13, 11, 14

12, 10, 13, 11, 14

# Задача про кофе

**Пример:** две группы людей принимают препарат перед забегом на сто метров

**Кофеин:** 12, 10

**Плацебо:** 13, 11, 14

12, 10, 13, 11, 14  
5   1   3   2   4

# Задача про кофе

**Пример:** две группы людей принимают препарат перед забегом на сто метров

**Кофеин:** 12, 10

**Плацебо:** 13, 11, 14

12, 10, 13, 11, 14

5    1    3    2    4

$$W_{\text{набл.}} = 5 + 1 = 6 \quad W_{\text{кр.}} = W_{1-\alpha} = 8$$

$$W = \sum_{i=1}^n rank(|X_i - m_0|) \cdot sign(X_i - m_0)$$

# Задача про кофе

**Пример:** две группы людей принимают препарат перед забегом на сто метров

**Кофеин:** 12, 10

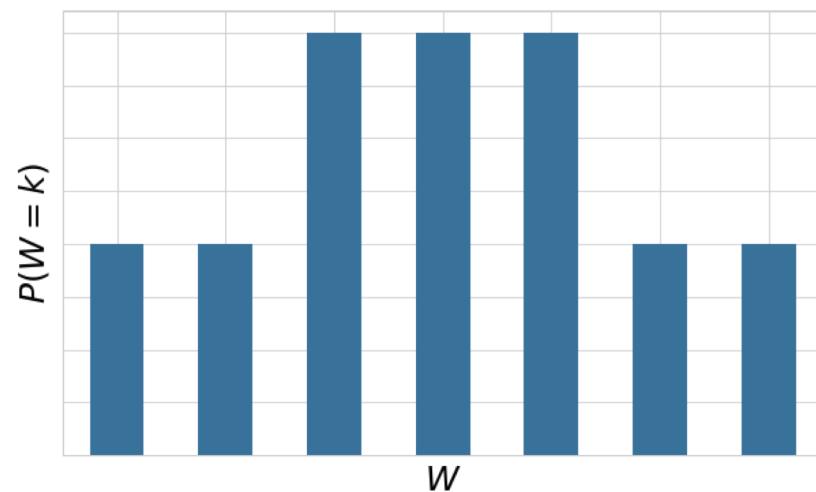
**Плацебо:** 13, 11, 14

12, 10, 13, 11, 14

5    1    3    2    4

$$W_{\text{набл.}} = 5 + 1 = 6$$

$$W_{\text{кр.}} = W_{1-\alpha} = 8$$



# Задача про кофе

**Пример:** две группы людей принимают препарат перед забегом на сто метров

**Кофеин:** 12, 10

**Плацебо:** 13, 11, 14

12, 10, 13, 11, 14

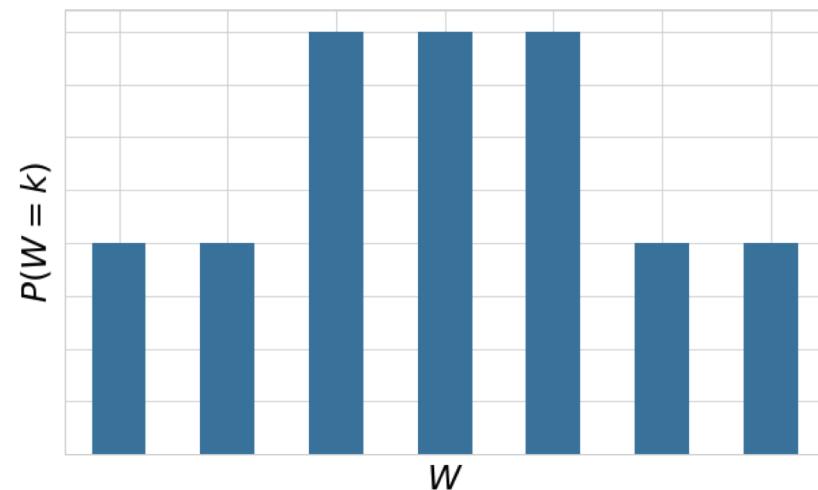
5    1    3    2    4

$$W_{\text{набл.}} = 5 + 1 = 6$$

$$W_{\text{кр.}} = W_{1-\alpha} = 8$$



Гипотеза,  
что влияния  
нет **не отвергается**



# Резюме

- Ранговые критерии превращают выборку в ранги наблюдений и позволяют сохранить больше информации

# Резюме

- Ранговые критерии превращают выборку в ранги наблюдений и позволяют сохранить больше информации
- Чтобы сохранить информацию, приходится делать дополнительные предположения

# Резюме

- Ранговые критерии превращают выборку в ранги наблюдений и позволяют сохранить больше информации
- Чтобы сохранить информацию, приходится делать дополнительные предположения
- Предположений о законе распределения, по-прежнему, не требуется

**Бутстрап**

# Бутстррап

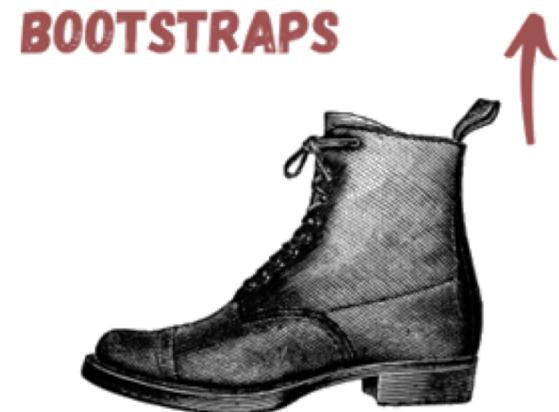
- Не для всех описательных статистик можно найти распределение в аналитическом виде (медиана, эксцесс, куртосис)

# Бутстррап

- Не для всех описательных статистик можно найти распределение в аналитическом виде (медиана, эксцесс, куртосис)
- Бутстррап помогает решить эту проблему

# Бутстреп

- “bootstrap” – кожаные петельки на задниках Ботинок



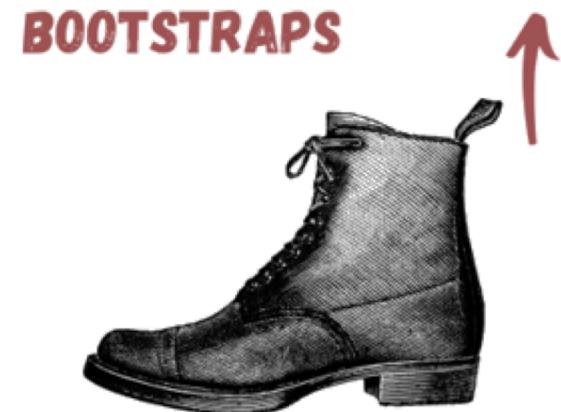
# Бутстрэп

- “bootstrap” – кожаные петельки на задниках Ботинок
- “lift himself by his bootstraps” - “вытащить себя из болота за задники ботинок”, “выбиться в люди благодаря собственным усилиям”



# Бутстрэп

- “bootstrap” – кожаные петельки на задниках Ботинок
- “lift himself by his bootstraps” - “вытащить себя из болота за задники ботинок”, “выбиться в люди благодаря собственным усилиям”



- Предложен в 1977 году  
~~бароном Мюнхгаузеном~~  
Б. Эфроном из Стенфорда

# Бутстррап

- **Идея метода:** имеющаяся выборка – это единственная информация об истинном распределении данных

# Бутстррап

- **Идея метода:** имеющаяся выборка – это единственная информация об истинном распределении данных
- Давайте приблизим истинное распределение эмпирическим, то есть “сами себя вытащим”

# Бутстррап

- **Идея метода:** имеющаяся выборка – это единственная информация об истинном распределении данных
- Давайте приблизим истинное распределение эмпирическим, то есть “сами себя вытащим”
- Предполагается, что бутстррап-распределение окажется похожим на реальное распределение

# Пример

- У Саши есть выборка из двух наблюдений: 1 и 4
- Нужно построить по этой выборке бутстреп-распределение для статистики  $\bar{x}$

# Пример

- У Саши есть выборка из двух наблюдений: 1 и 4
- Нужно построить по этой выборке бутстррап-распределение для статистики  $\bar{x}$

**Выборки с повторениями:**

$$1,4 \Rightarrow \bar{x} = 2.5$$

$$4,1 \Rightarrow \bar{x} = 2.5$$

$$1,1 \Rightarrow \bar{x} = 1$$

$$4,4 \Rightarrow \bar{x} = 4$$

# Пример

- У Саши есть выборка из двух наблюдений: 1 и 4
- Нужно построить по этой выборке бутстррап-распределение для статистики  $\bar{x}$

Выборки с повторениями:

$$1,4 \Rightarrow \bar{x} = 2.5$$

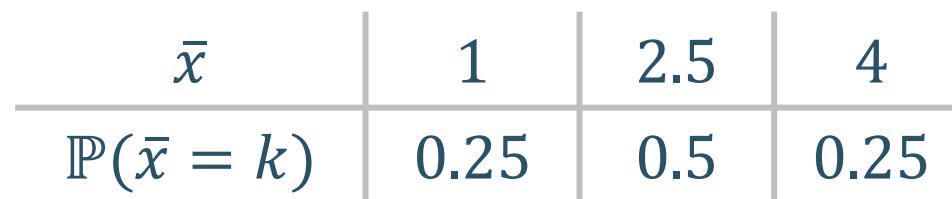
$$4,1 \Rightarrow \bar{x} = 2.5$$

$$1,1 \Rightarrow \bar{x} = 1$$

$$4,4 \Rightarrow \bar{x} = 4$$

Всего вариантов выборок:

$$n^n = 2^2 = 4$$



# Пример

- У Саши есть выборка из двух наблюдений: 1 и 4
- Нужно построить по этой выборке бутстррап-распределение для статистики  $\bar{x}$

Всего вариантов выборок:

$$n^n = 2^2 = 4$$

- Строить такие распределения для больших выборок дорого
- Задача слишком сложная, а точность излишняя
- **Выход:** симуляции

# Схема бутстрата

- Извлечение выборок из генеральной совокупности – сэмплирование из неизвестного распределения  $F(x)$

# Схема бутстрата

- Извлечение выборок из генеральной совокупности – сэмплирование из неизвестного распределения  $F(x)$
- У нас есть оценка для  $F(x) - \hat{F}_n(x)$

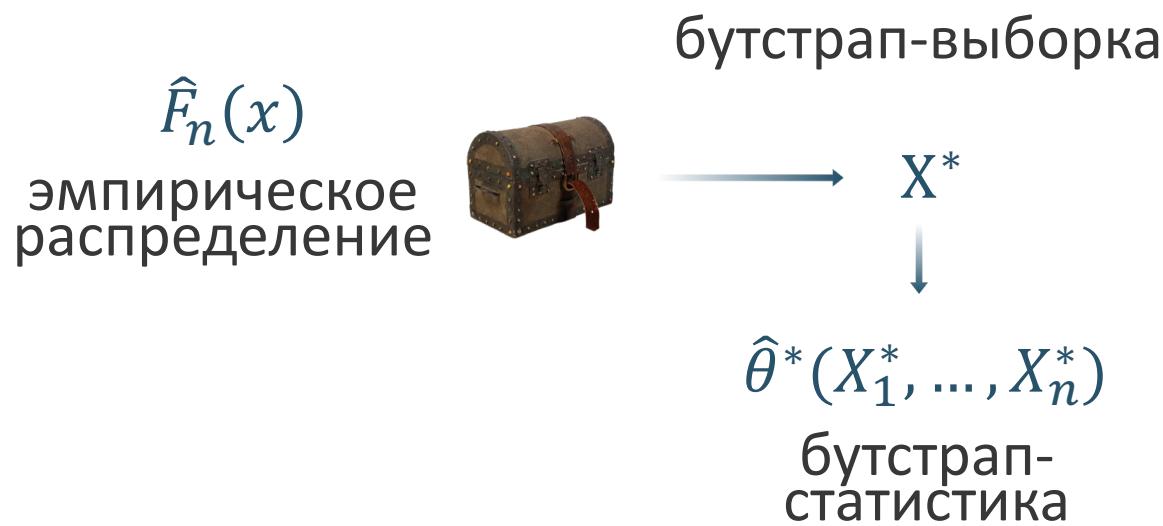
# Схема бутстрата

- Извлечение выборок из генеральной совокупности – сэмплирование из неизвестного распределения  $F(x)$
- У нас есть оценка для  $F(x) - \hat{F}_n(x)$
- Сэмплировать из такого распределения – то же самое, что брать выборки с повторениями объёма  $n$

# Схема бутстрата

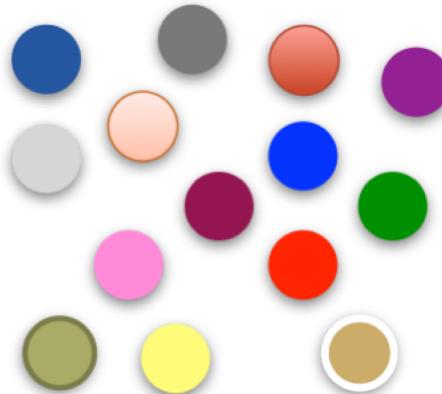


# Схема бутстрата

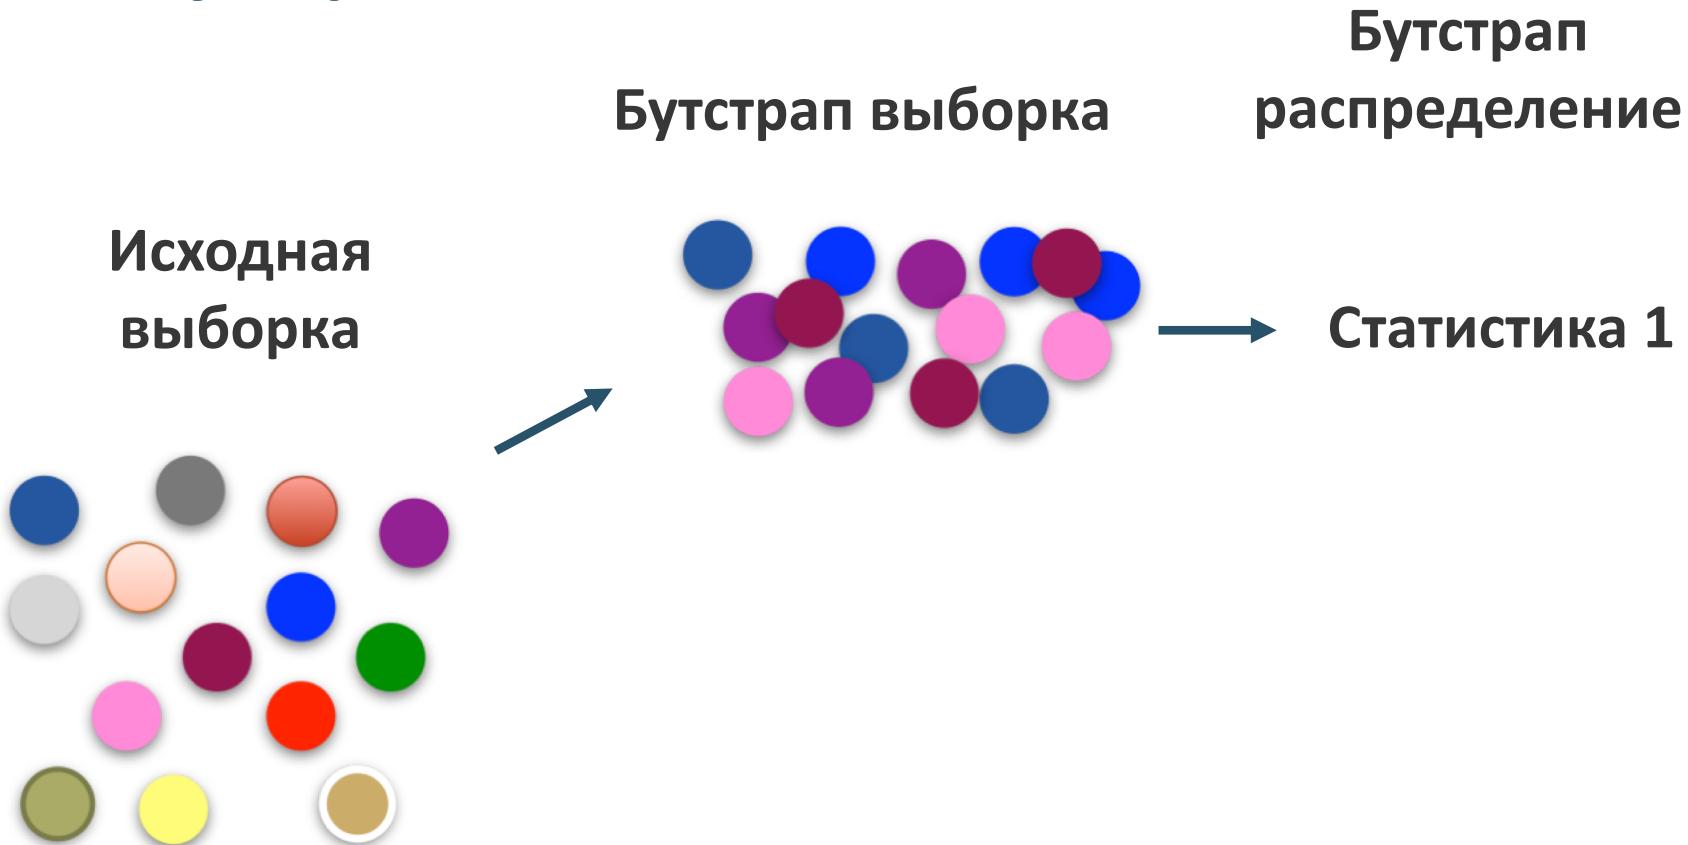


# Схема бутстрата

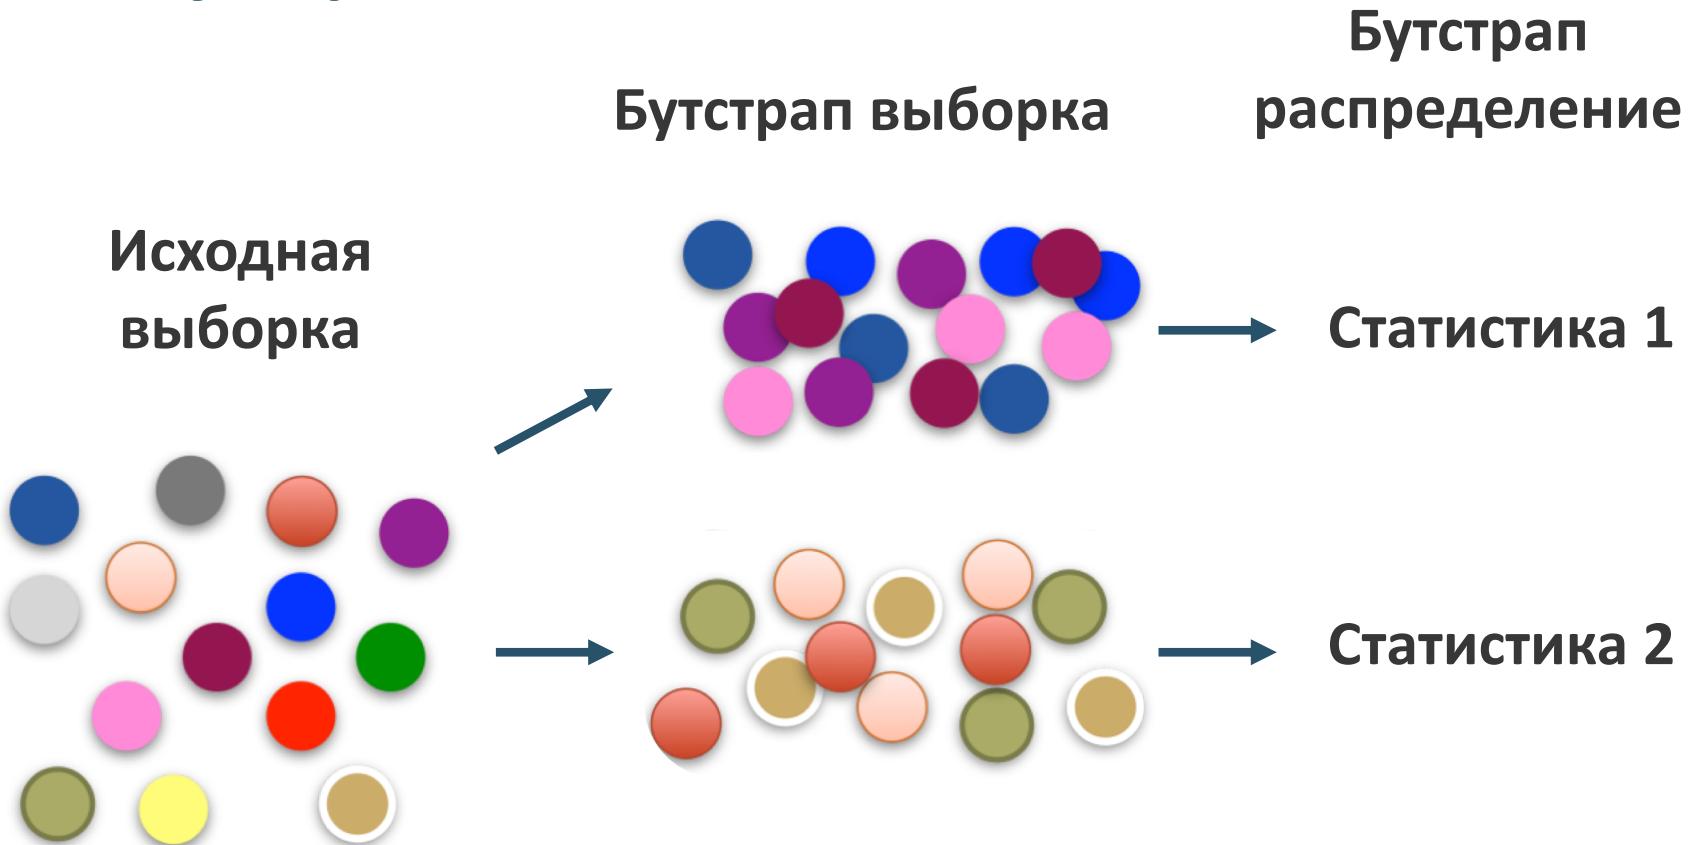
Исходная  
выборка



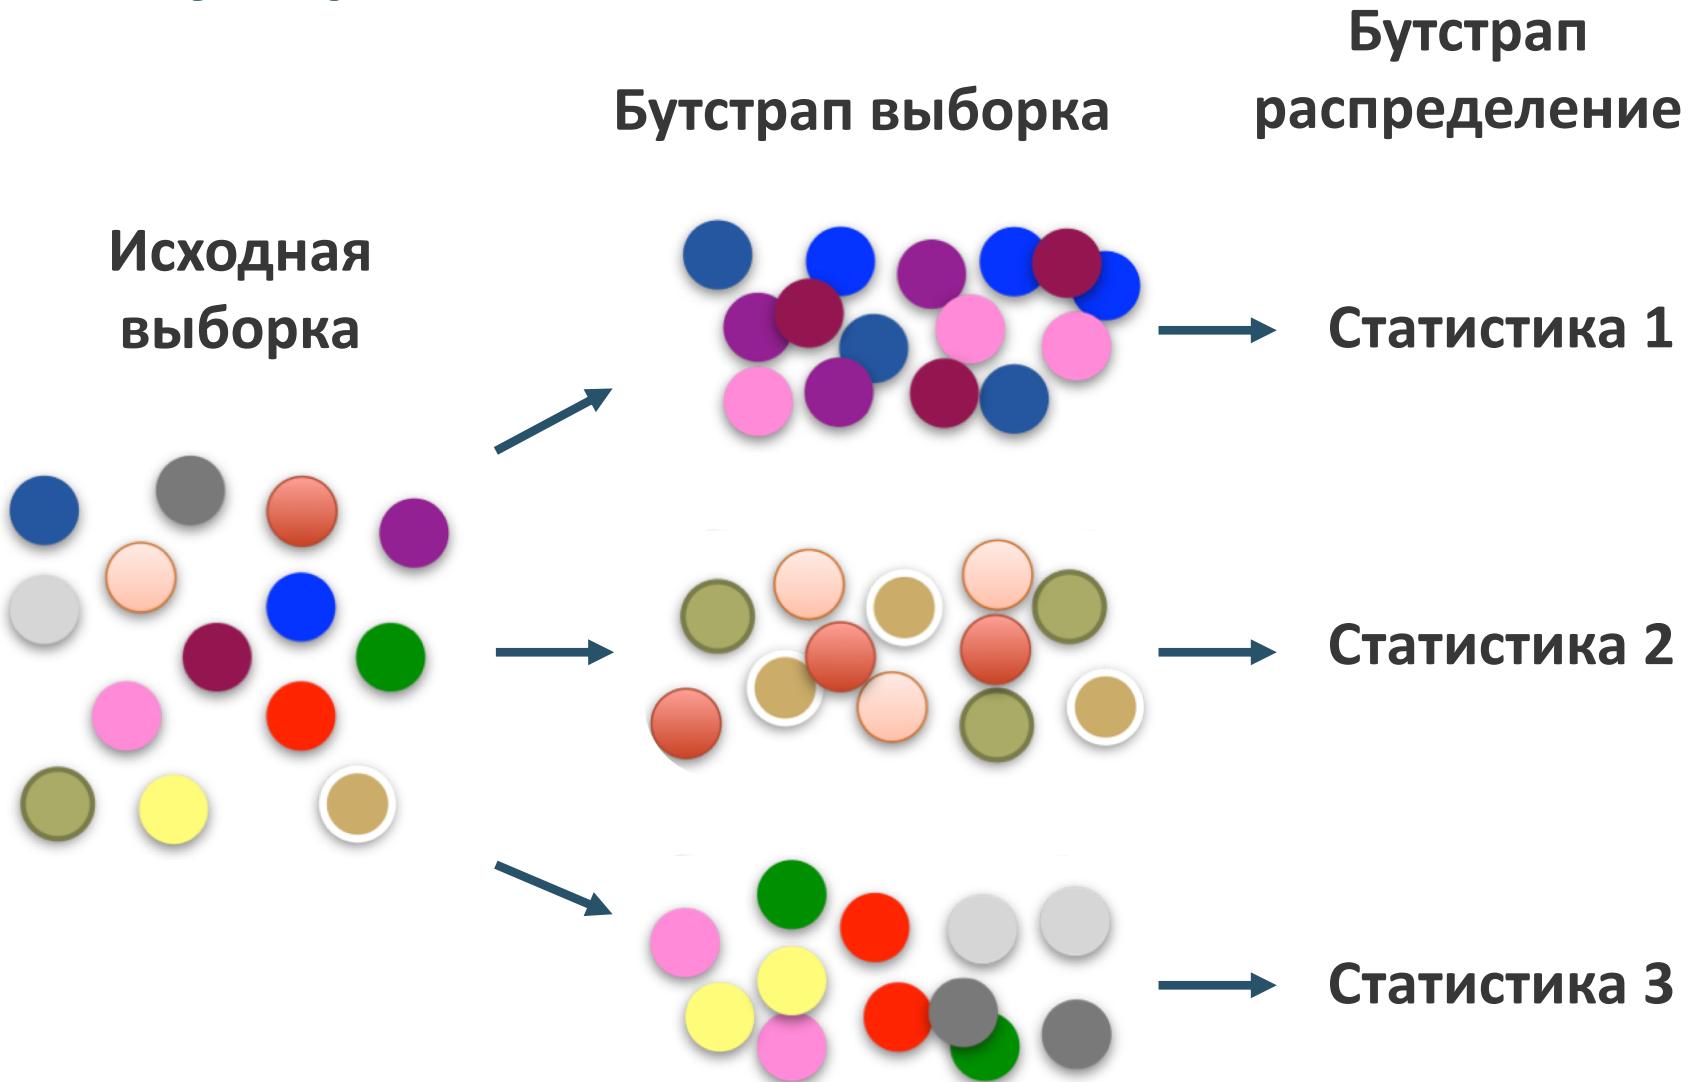
# Схема бутстрата



# Схема бутстрата



# Схема бутстрата



# Схема бутстрата

- Генерируем  $B$  “псевдовыборок” с повторениями объёма  $n$  и оцениваем настоящее распределение “псевдоэмпирическим”

# Схема бутстрата

- Генерируем  $B$  “псевдовыборок” с повторениями объёма  $n$  и оцениваем настоящее распределение “псевдоэмпирическим”
- По каждой выборке вычисляем интересующую нас статистику, получаем для неё бутстрат-распределение

# Схема бутстрата

- Генерируем  $B$  “псевдовыборок” с повторениями объёма  $n$  и оцениваем настоящее распределение “псевдоэмпирическим”
- По каждой выборке вычисляем интересующую нас статистику, получаем для неё бутстрап-распределение
- **Эфронов доверительный интервал:** находим выборочные квантили бутстрап-распределения

# Схема бутстрата

- Генерируем  $B$  “псевдовыборок” с повторениями объёма  $n$  и оцениваем настоящее распределение “псевдоэмпирическим”
- По каждой выборке вычисляем интересующую нас статистику, получаем для неё бутстрат-распределение
- **Эфронов доверительный интервал:** находим выборочные квантили бутстрат-распределения
- В таком доверительном интервале возникает смещение  $\Rightarrow$  более сложные техники бутстрата

# Доверительный интервал Эфона

**Бутстранируем:** оценку неизвестного параметра

**Сэмплируем:**  $x_1^*, \dots, x_n^*$

**Считаем:**  $\hat{\theta}^*$

**Повторяем:**  $B$  раз

**Строим распределение:**  $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$

**Интервал:**  $[\hat{\theta}_{\frac{\alpha}{2}}^*; \hat{\theta}_{1-\frac{\alpha}{2}}^*]$

# Доверительный интервал Эфона

Бутстранируем: оценку неизвестного параметра

Сэмплируем:  $x_1^*, \dots, x_n^*$

Считаем:  $\hat{\theta}^*$

Повторяем:  $B$  раз

Строим распределение:  $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$

Интервал:  $[\hat{\theta}_{\frac{\alpha}{2}}^*; \hat{\theta}_{1-\frac{\alpha}{2}}^*]$

- ! Если распределение выборки несимметрично, такой доверительный интервал усиливает смещение, присущее изначальной выборке

**Бутстрап**

# Центрирование

- Чтобы не создавать искусственное смещение между  $\hat{\theta}$  и  $\theta$ , нужно бутстрэпировать центрированную статистику

# Центрирование

- Чтобы не создавать искусственное смещение между  $\hat{\theta}$  и  $\theta$ , нужно бутстрэпировать центрированную статистику
- Хотим бутстрэпировать разность  $\hat{\theta} - \theta$

# Центрирование

- Чтобы не создавать искусственное смещение между  $\hat{\theta}$  и  $\theta$ , нужно бутстрэпировать центрированную статистику
- Хотим бутстрэпировать разность  $\hat{\theta} - \theta$
- Бутстрэпируя  $\hat{\theta}$ , мы подсчитываем её каждый раз заново, но на бутстрэповских выборках,  $\hat{\theta}^*$

# Центрирование

- Чтобы не создавать искусственное смещение между  $\hat{\theta}$  и  $\theta$ , нужно бутстрартировать центрированную статистику
- Хотим бутстрартировать разность  $\hat{\theta} - \theta$
- Бутстрарпируя  $\hat{\theta}$ , мы подсчитываем её каждый раз заново, но на бутстрарповских выборках,  $\hat{\theta}^*$
- Бутстрарповским аналогом для  $\theta$  будет  $\hat{\theta}$ , так как мы сэмплируем данные их эмпирического распределения

# Центрирование

- Чтобы не создавать искусственное смещение между  $\hat{\theta}$  и  $\theta$ , нужно бутстрартировать центрированную статистику
- Хотим бутстрартировать разность  $\hat{\theta} - \theta$
- Бутстрарпируя  $\hat{\theta}$ , мы подсчитываем её каждый раз заново, но на бутстрарповских выборках,  $\hat{\theta}^*$
- Бутстрарповским аналогом для  $\theta$  будет  $\hat{\theta}$ , так как мы сэмплируем данные их эмпирического распределения
- Бутстрарповский аналог для  $\hat{\theta} - \theta$  – это  $\hat{\theta}^* - \hat{\theta}$

# Доверительный интервал Холла

Бутстранируем: Отклонение оценки  
от истинного значения

# Доверительный интервал Холла

Бутстранируем: Отклонение оценки  
от истинного значения

Сэмплируем:  $x_1^*, \dots, x_n^*$

# Доверительный интервал Холла

**Бутстрапируем:** Отклонение оценки от истинного значения

**Сэмплируем:**  $x_1^*, \dots, x_n^*$

**Считаем:**  $\hat{q}_i^* = \hat{\theta}^* - \hat{\theta}$

# Доверительный интервал Холла

**Бутстрапируем:** Отклонение оценки от истинного значения

**Сэмплируем:**  $x_1^*, \dots, x_n^*$

**Считаем:**  $\hat{q}_i^* = \hat{\theta}^* - \hat{\theta}$

**Повторяем:**  $B$  раз

# Доверительный интервал Холла

**Бутстранируем:** Отклонение оценки от истинного значения

**Сэмплируем:**  $x_1^*, \dots, x_n^*$

**Считаем:**  $\hat{q}_i^* = \hat{\theta}^* - \hat{\theta}$

**Повторяем:**  $B$  раз

**Строим распределение:**  $\hat{q}_1^*, \dots, \hat{q}_B^*$

# Доверительный интервал Холла

**Бутстранируем:** Отклонение оценки от истинного значения

**Сэмплируем:**  $x_1^*, \dots, x_n^*$

**Считаем:**  $\hat{q}_i^* = \hat{\theta}^* - \hat{\theta}$

**Повторяем:**  $B$  раз

**Строим распределение:**  $\hat{q}_1^*, \dots, \hat{q}_B^*$

**Интервал:**  $[\hat{\theta} - \hat{q}_{1-\frac{\alpha}{2}}^*; \hat{\theta} - \hat{q}_{\frac{\alpha}{2}}^*]$

# t-процентильный доверительный интервал

Бутстранируем: t - статистику

# $t$ -процентильный доверительный интервал

Бутстранируем:  $t$  - статистику

Сэмплируем:  $x_1^*, \dots, x_n^*$

# t-процентильный доверительный интервал

Бутстранируем: t - статистику

Сэмплируем:  $x_1^*, \dots, x_n^*$

Считаем:  $t_i^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$

# $t$ -процентильный доверительный интервал

Бутстранируем:  $t$  - статистику

Сэмплируем:  $x_1^*, \dots, x_n^*$

Считаем:  $t_i^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$

Повторяем:  $B$  раз

# $t$ -процентильный доверительный интервал

Бутстранируем:  $t$  - статистику

Сэмплируем:  $x_1^*, \dots, x_n^*$

Считаем:  $t_i^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$

Повторяем:  $B$  раз

Строим распределение:  $t_1^*, \dots, t_B^*$

# t-процентильный доверительный интервал

Бутстранируем: t - статистику

Сэмплируем:  $x_1^*, \dots, x_n^*$

Считаем:  $t_i^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$

Повторяем:  $B$  раз

Строим распределение:  $t_1^*, \dots, t_B^*$

Интервал:  $[\hat{\theta} - t_{1-\frac{\alpha}{2}}^* se(\hat{\theta}); \hat{\theta} + t_{\frac{\alpha}{2}}^* se(\hat{\theta})]$

# $t$ -процентильный доверительный интервал

Бутстранируем:  $t$  - статистику

Сэмплируем:  $x_1^*, \dots, x_n^*$

Считаем:  $t_i^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$

Повторяем:  $B$  раз

Строим распределение:  $t_1^*, \dots, t_B^*$

Интервал:  $[\hat{\theta} - t_{1-\frac{\alpha}{2}}^* se(\hat{\theta}); \hat{\theta} + t_{\frac{\alpha}{2}}^* se(\hat{\theta})]$

❗ Если бутстрарировать  $|\hat{\theta}^* - \hat{\theta}|$ , можно получить симметричный интервал

# Проверка гипотез при помощи бутстрата

$$H_0: \theta = \theta_0$$

$$H_a: \theta > \theta_0$$

t-статистика:

$$t = \frac{(\hat{\theta} - \theta_0)}{se(\hat{\theta})}$$

Бутстррап-аналог:

$$t^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$$

- <http://quantile.ru/03/03-SA.pdf>

# Проверка гипотез при помощи бутстрата

$$H_0: \theta = \theta_0$$

$$H_a: \theta > \theta_0$$

t-статистика:

$$t = \frac{(\hat{\theta} - \theta_0)}{se(\hat{\theta})}$$

Бутстррап-аналог:

$$t^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$$

- Гипотеза отвергается, если  $t_{obs} > t_{1-\alpha}^*$

► <http://quantile.ru/03/03-SA.pdf>

# Проверка гипотез при помощи бутстрата

$$H_0: \theta = \theta_0$$

$$H_a: \theta > \theta_0$$

t-статистика:

$$t = \frac{(\hat{\theta} - \theta_0)}{se(\hat{\theta})}$$

Бутстррап-аналог:

$$t^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$$

- Гипотеза отвергается, если  $t_{obs} > t_{1-\alpha}^*$
- По аналогии можно проверять гипотезы против других альтернатив

► <http://quantile.ru/03/03-SA.pdf>

# Проверка гипотез при помощи бутстрата

$$H_0: \theta = \theta_0$$

$$H_a: \theta > \theta_0$$

t-статистика:

$$t = \frac{(\hat{\theta} - \theta_0)}{se(\hat{\theta})}$$

Бутстррап-аналог:

$$t^* = \frac{(\hat{\theta}^* - \hat{\theta})}{se(\hat{\theta}^*)}$$

- Гипотеза отвергается, если  $t_{obs} > t_{1-\alpha}^*$
- По аналогии можно проверять гипотезы против других альтернатив
- Для более сложных гипотез есть специальные бутстрраповские алгоритмы проверки

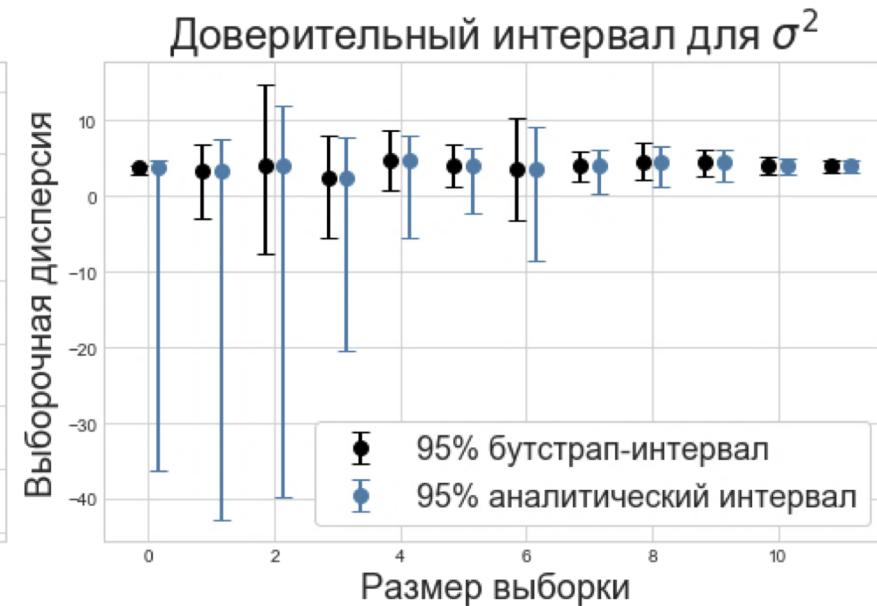
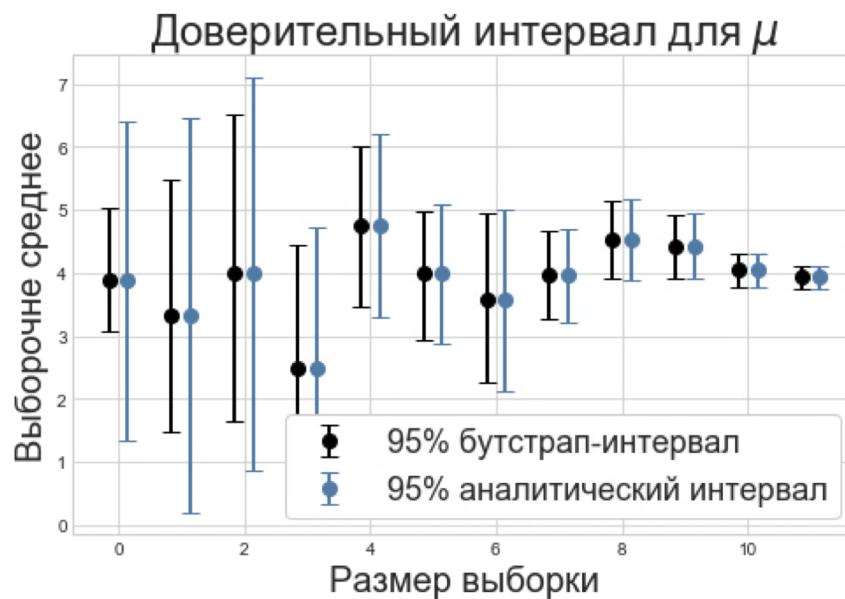
► <http://quantile.ru/03/03-SA.pdf>

# Проблемы бутстрата

- Чтобы бутстррап сработал, выборка должна быть  
репрезентативной

# Проблемы бутстрата

- Чтобы бутстрат сработал, выборка должна быть репрезентативной



- Если исходная выборка маленькая, бутстратовский доверительный интервал будет уже аналитического, так как в выборке недостаточно “неопределенности”

# Проблемы бутстрата

- Если в данных есть структура (регрессия, временные ряды), бутстррап нужно устроить так, чтобы учитывать её ⇒ разные виды бутстрата

# Проблемы бутстрата

- Если в данных есть структура (регрессия, временные ряды), бутстррап нужно устроить так, чтобы учитывать её ⇒ разные виды бутстрата
- Бутстррап ненадёжно работает в хвостах распределения из-за маленького числа наблюдений: мы можем хорошо оценить медиану, но не 99% квантиль

# Проблемы бутстрата

- Если в данных есть структура (регрессия, временные ряды), бутстррап нужно устроить так, чтобы учитывать её ⇒ разные виды бутстрата
- Бутстррап ненадёжно работает в хвостах распределения из-за маленького числа наблюдений: мы можем хорошо оценить медиану, но не 99% квантиль
- Если у распределения тяжёлые хвосты, бутстррап может работать некорректно и в средиземье

# Сколько процентов выборки берем

У Винни-Пуха есть 100 песенок (кричалок, вопелок, пыхтелок и сопелок). Каждый день он поёт одну равновероятно наугад. Одну и ту же песенку он может петь несколько раз. Сколько в среднем песенок не будут спеты ни разу за 100 дней?

# Сколько процентов выборки берем

У Винни-Пуха есть 100 песенок (кричалок, вопелок, пыхтелок и сопелок). Каждый день он поёт одну равновероятно наугад. Одну и ту же песенку он может петь несколько раз. Сколько в среднем песенок не будут спеты ни разу за 100 дней?

- Вероятность конкретной песенки  $\frac{1}{n}$

# Сколько процентов выборки берем

У Винни-Пуха есть 100 песенок (кричалок, вопелок, пыхтелок и сопелок). Каждый день он поёт одну равновероятно наугад. Одну и ту же песенку он может петь несколько раз. Сколько в среднем песенок не будут спеты ни разу за 100 дней?

- Вероятность конкретной песенки  $\frac{1}{n}$
- В конкретный день не споёт эту песенку с вероятностью  $1 - \frac{1}{n}$

# Сколько процентов выборки берем

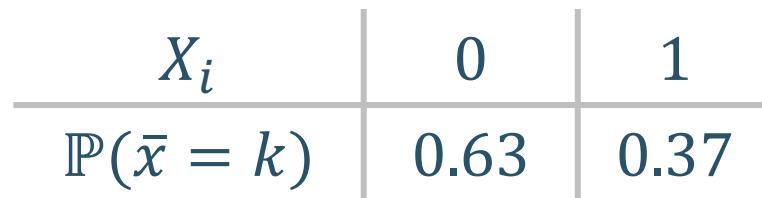
У Винни-Пуха есть 100 песенок (кричалок, вопелок, пыхтелок и сопелок). Каждый день он поёт одну равновероятно наугад. Одну и ту же песенку он может петь несколько раз. Сколько в среднем песенок не будут спеты ни разу за 100 дней?

- Вероятность конкретной песенки  $\frac{1}{n}$
- В конкретный день не споёт эту песенку с вероятностью  $1 - \frac{1}{n}$
- Не споёт песенку ни разу с вероятностью

$$\left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1} = \frac{1}{e} \approx 0.37 \text{ при } n \rightarrow \infty$$

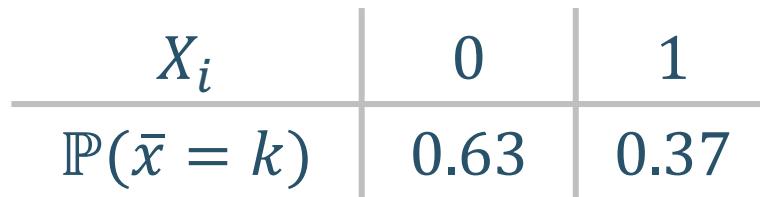
# Пример

- Случайная величина  $X_i = 1$ , если песенка не была ни разу спета за  $n$  дней



# Пример

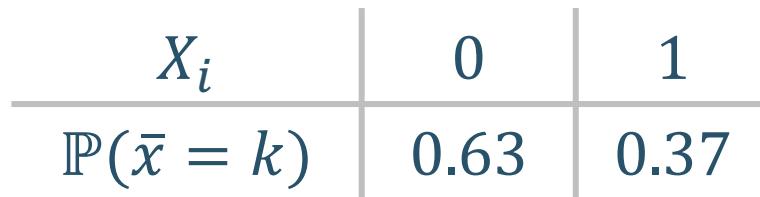
- Случайная величина  $X_i = 1$ , если песенка не была ни разу спета за  $n$  дней



- Случайная величина  $Y = X_1 + \dots + X_n$  – число песенок, которое Винни-Пух ни разу не споёт за  $n$  дней

# Пример

- Случайная величина  $X_i = 1$ , если песенка не была ни разу спета за  $n$  дней

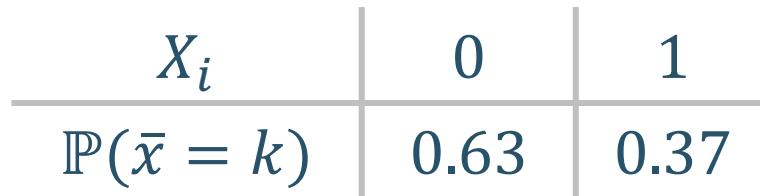


- Случайная величина  $Y = X_1 + \dots + X_n$  – число песенок, которое Винни-Пух ни разу не споёт за  $n$  дней

$$\mathbb{E}(Y) = \mathbb{E}(X_1 + \dots + X_n) = n \cdot \mathbb{E}(X_1) = 0.37 \cdot n$$

# Пример

- Случайная величина  $X_i = 1$ , если песенка не была ни разу спета за  $n$  дней



- Случайная величина  $Y = X_1 + \dots + X_n$  – число песенок, которое Винни-Пух ни разу не споёт за  $n$  дней

$$\mathbb{E}(Y) = \mathbb{E}(X_1 + \dots + X_n) = n \cdot \mathbb{E}(X_1) = 0.37 \cdot n$$

! В одной бутстрраповской выборке будет в среднем оказываться 63% наблюдений

# Резюме

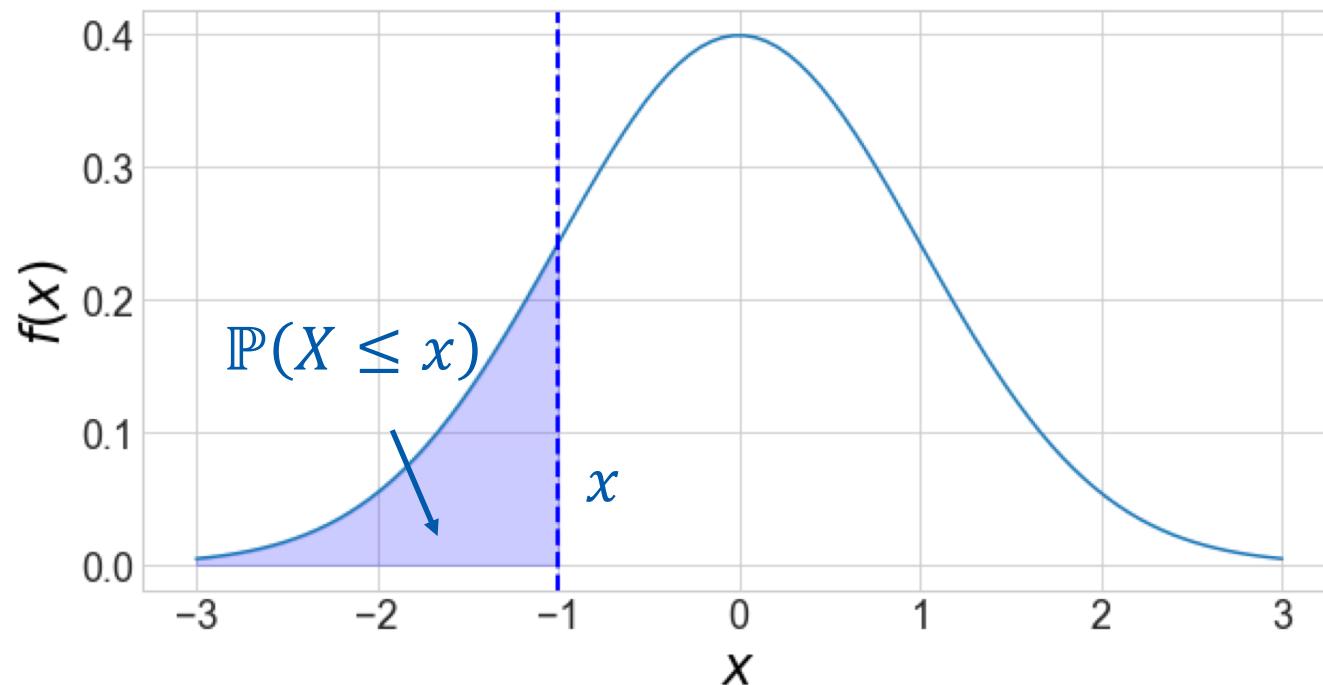
- Бутстреп – это метод получения критических значений статистики
- Процедура может требовать много времени для оценки
- При некоторых ограничениях бутстреп даёт состоятельные оценки, но не в общем случае
- Плохо работает для статистик, значение которых зависит от небольшого числа элементов выборки

# Эмпирическая функция распределения

# Функция распределения

**Функция распределения** – функция, которая определяет вероятность события  $X \leq x$ , то есть

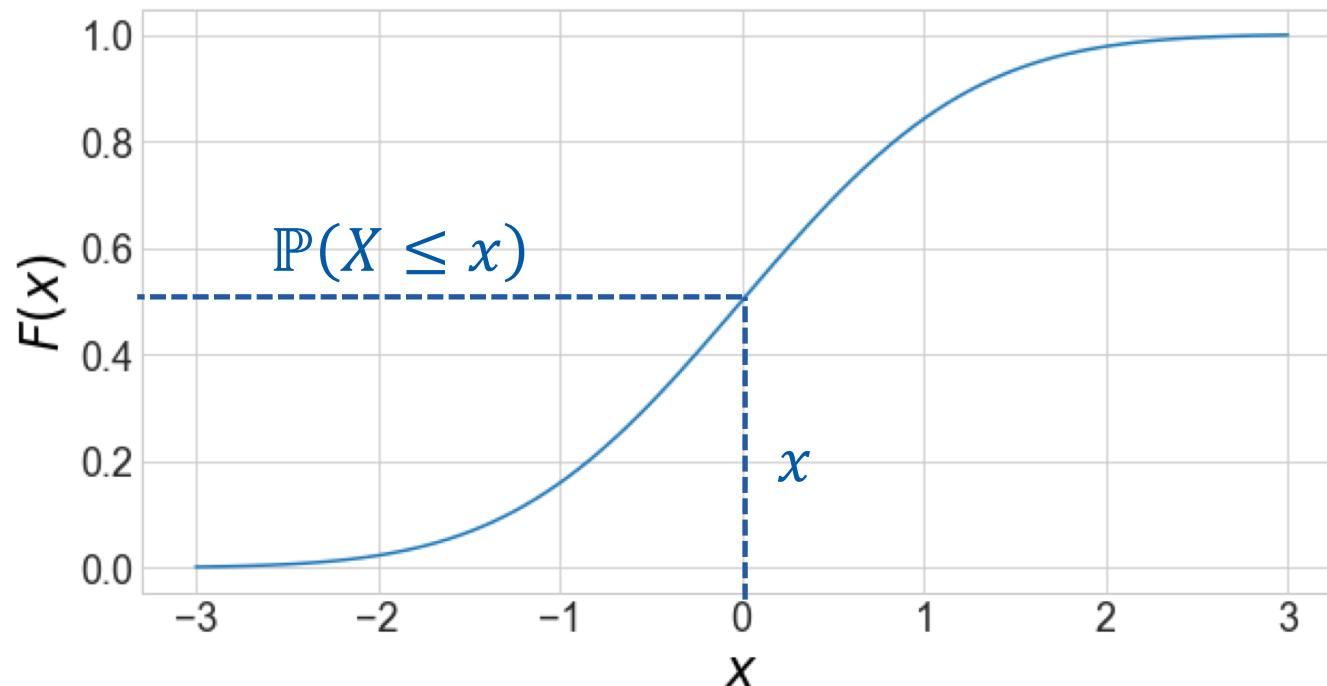
$$F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(t) \, dt, f(t) \text{ – плотность}$$



# Функция распределения

**Функция распределения** – функция, которая определяет вероятность события  $X \leq x$ , то есть

$$F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(t) \, dt, f(t) \text{ – плотность}$$



# Эмпирическая функция распределения

**Функция распределения** – функция, которая определяет вероятность события  $X \leq x$ , то есть

$$F(x) = \mathbb{P}(X \leq x)$$

# Эмпирическая функция распределения

**Функция распределения** – функция, которая определяет вероятность события  $X \leq x$ , то есть

$$F(x) = \mathbb{P}(X \leq x)$$

**Эмпирическая функция распределения** – функция, которая определяет для каждого  $x$  частоту события  $X \leq x$ , то есть

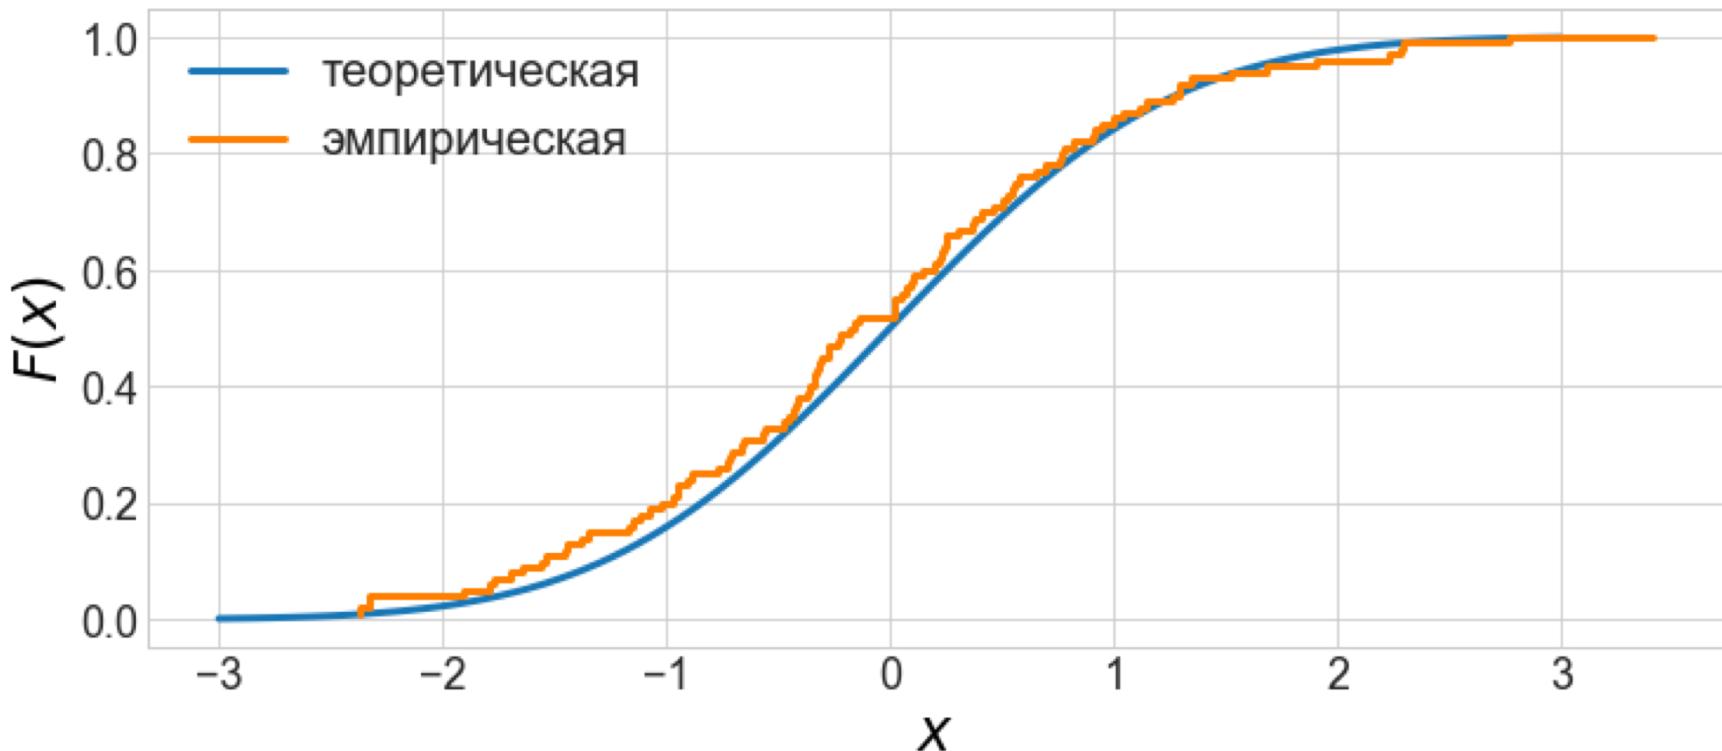
$$\hat{F}_n(x) = \widehat{\mathbb{P}}(X \leq x) = \frac{1}{n} \sum_{i=1}^n [X_i \leq x],$$

где  $[ ]$  – индикаторная функция, то есть:

$$[X_i \leq x] = \begin{cases} 1, & X_i \leq x \\ 0, & \text{иначе} \end{cases}$$

# Эмпирическая функция распределения

Чем больше выборка, тем чаще ступеньки и тем больше эмпирическая функция распределения похожа на теоретическую.



# Эмпирическая функция распределения

Эмпирическая функция распределения – статистика, оцениваемая по данным



Какими свойствами  
она обладает?

# Свойства эмпирической функции распределения

1. Несмешённость:  $\mathbb{E}(\hat{F}_n(x)) = F_X(x)$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}([X_i \leq x]) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}([X_i \leq x]) =$$

$$\frac{1}{n} \sum_{i=1}^n (1 \cdot \mathbb{P}(X_i \leq x) + 0 \cdot \mathbb{P}(X_i > x)) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}([X_i \leq x]) =$$

$$\frac{1}{n} \sum_{i=1}^n (1 \cdot \mathbb{P}(X_i \leq x) + 0 \cdot \mathbb{P}(X_i > x)) = \frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i \leq x) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}([X_i \leq x]) =$$

$$\frac{1}{n} \sum_{i=1}^n (1 \cdot \mathbb{P}(X_i \leq x) + 0 \cdot \mathbb{P}(X_i > x)) = \frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i \leq x) =$$

$$\frac{1}{n} \sum_{i=1}^n F_X(x) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}([X_i \leq x]) =$$

$$\frac{1}{n} \sum_{i=1}^n (1 \cdot \mathbb{P}(X_i \leq x) + 0 \cdot \mathbb{P}(X_i > x)) = \frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i \leq x) =$$

$$\frac{1}{n} \sum_{i=1}^n F_X(x) = \frac{1}{n} \cdot n \cdot F_X(x) =$$

# Эмпирическая функция распределения

$$\mathbb{E}(\hat{F}_n(x)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n [X_i \leq x]\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}([X_i \leq x]) =$$

$$\frac{1}{n} \sum_{i=1}^n (1 \cdot \mathbb{P}(X_i \leq x) + 0 \cdot \mathbb{P}(X_i > x)) = \frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i \leq x) =$$

$$\frac{1}{n} \sum_{i=1}^n F_X(x) = \frac{1}{n} \cdot n \cdot F_X(x) = F_X(x)$$

# Свойства эмпирической функции распределения

1. Несмешённость:  $\mathbb{E}(\hat{F}_n(x)) = F_X(x)$
2. Состоятельность:  $\operatorname{plim}_{n \rightarrow \infty} \hat{F}_n(x) = F_X(x)$

# Эмпирическая функция распределения

$$\hat{F}_n(x) = \widehat{\mathbb{P}}(X \leq x) = \frac{1}{n} \sum_{i=1}^n [X_i \leq x] =$$

# Эмпирическая функция распределения

$$\hat{F}_n(x) = \widehat{\mathbb{P}}(X \leq x) = \frac{1}{n} \sum_{i=1}^n [X_i \leq x] =$$
$$= \frac{[X_1 \leq x] + \cdots + [X_n \leq x]}{n}$$

# Эмпирическая функция распределения

$$\hat{F}_n(x) = \widehat{\mathbb{P}}(X \leq x) = \frac{1}{n} \sum_{i=1}^n [X_i \leq x] =$$
$$= \frac{[X_1 \leq x] + \cdots + [X_n \leq x]}{n} \xrightarrow{p} F_X(x) \text{ при } n \rightarrow \infty$$

По ЗБЧ наша оценка состоятельна

# Свойства эмпирической функции распределения

1. Несмешённость:  $\mathbb{E}(\hat{F}_n(x)) = F_X(x)$

2. Состоятельность:  $\operatorname{plim}_{n \rightarrow \infty} \hat{F}_n(x) = F_X(x)$

3. Асимптотическая нормальность:

$$\hat{F}_n(x) \stackrel{asy}{\sim} N\left(F_X(x), \frac{F_X(x) \cdot (1 - F_X(x))}{n}\right)$$

# Свойства эмпирической функции распределения

1. Несмешённость:  $\mathbb{E}(\hat{F}_n(x)) = F_X(x)$

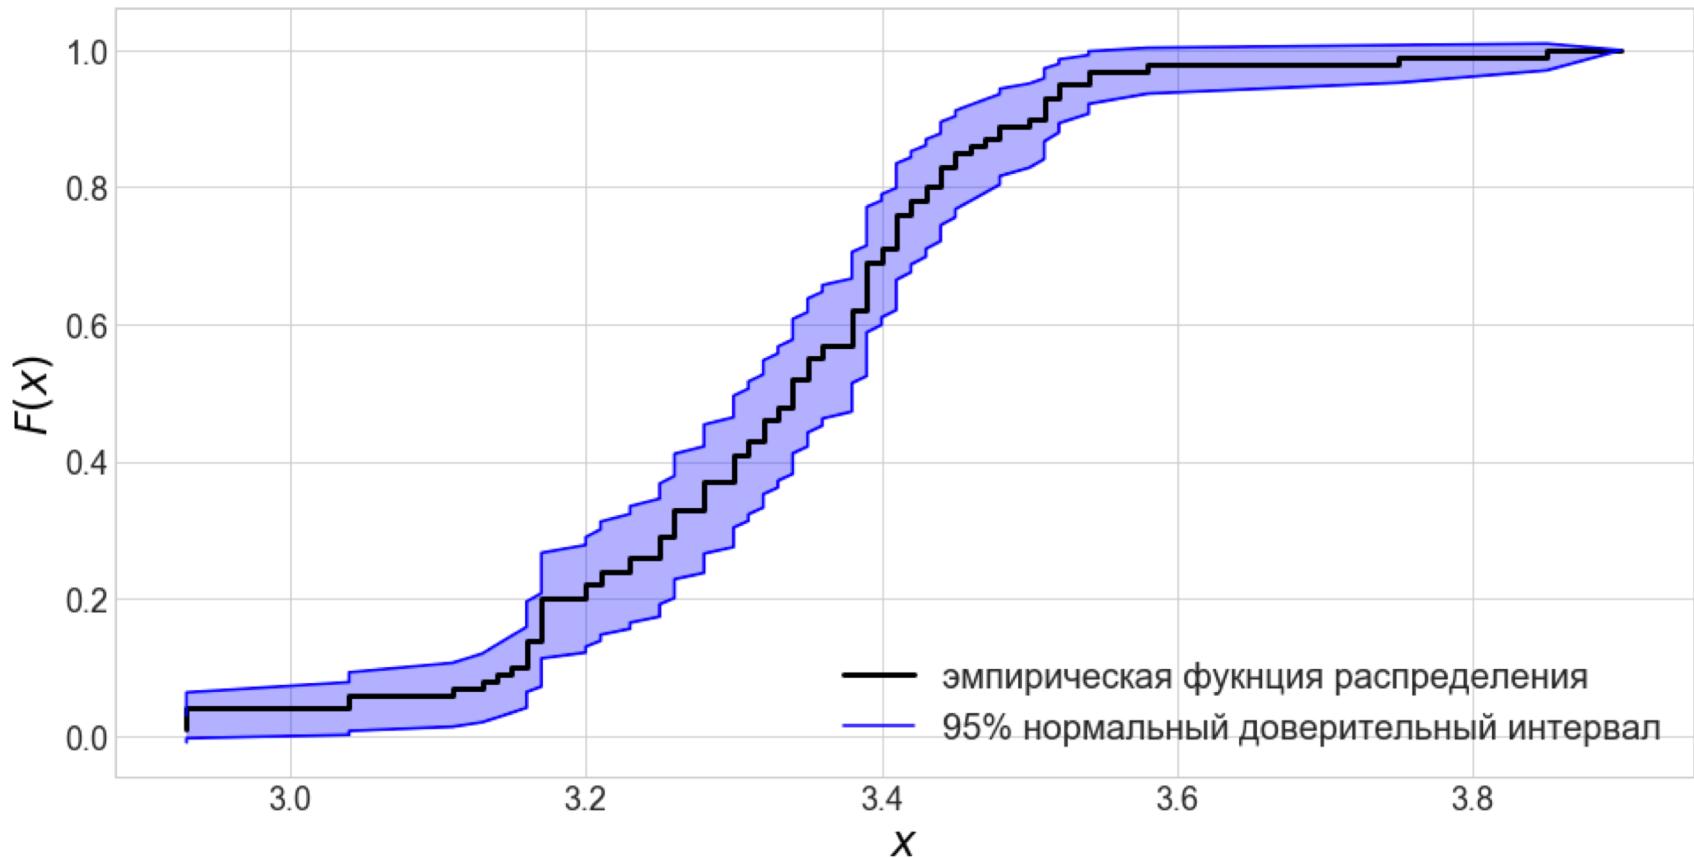
2. Состоятельность:  $\operatorname{plim}_{n \rightarrow \infty} \hat{F}_n(x) = F_X(x)$

3. Асимптотическая нормальность:

$$\hat{F}_n(x) \stackrel{asy}{\sim} N\left(F_X(x), \frac{\hat{F}_n(x) \cdot (1 - \hat{F}_n(x))}{n}\right)$$

# Нормальный доверительный интервал

ЦПТ помогает построить доверительный интервал для эмпирической функции распределения в каждой точке



# Критерий Колмогорова

# Критерии согласия

- **Критерии согласия** – критерий о виде неизвестного закона распределения

$$H_0: X \sim F_X(x)$$

$H_a$ : гипотеза  $H_0$  неверна

# Критерии согласия

- **Критерии согласия** – критерий о виде неизвестного закона распределения

$$H_0: X \sim F_X(x)$$

$H_a$ : гипотеза  $H_0$  неверна

- Распределение случайной величины описывается её функцией распределения

$$H_0: F_X(x) = F_0(x)$$

$$H_a: F_X(x) \neq F_0(x)$$

# Критерии согласия

- **Критерии согласия** – критерий о виде неизвестного закона распределения

$$H_0: X \sim F_X(x)$$

$H_a$ : гипотеза  $H_0$  неверна

- Распределение случайной величины описывается её функцией распределения

$$H_0: F_X(x) = F_0(x)$$

$$H_a: F_X(x) \neq F_0(x)$$

- Параметры неизвестного закона распределения мы фиксируем как нулевую гипотезу

# Критерии согласия

- Критерии о неизвестных законах распределения строятся по аналогии с параметрическими

# Критерии согласия

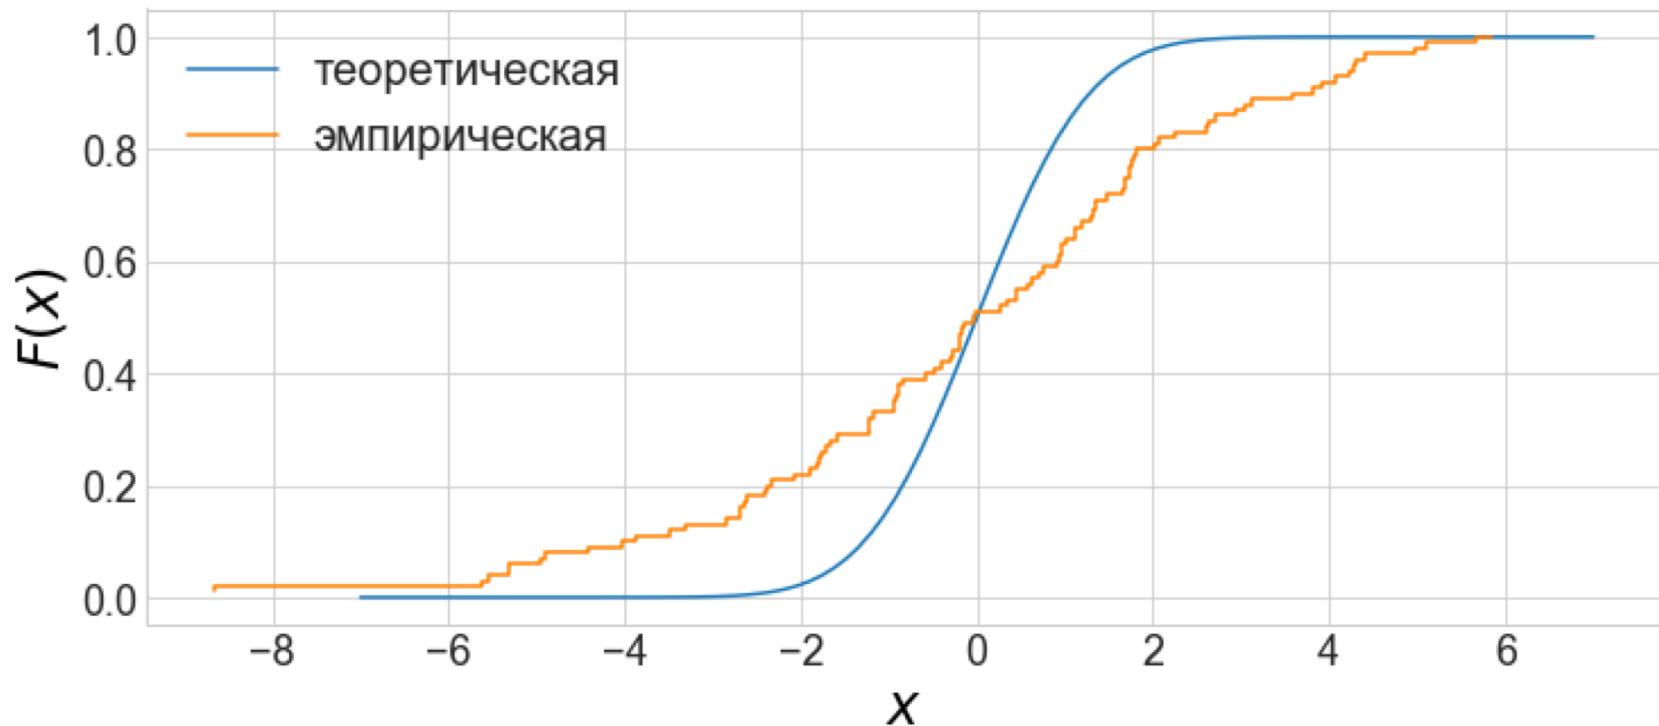
- Критерии о неизвестных законах распределения строятся по аналогии с параметрическими
- У нас в распоряжении есть выборка, по ней мы оценили эмпирическую функцию распределения  $\hat{F}_n(x)$

# Критерии согласия

- Критерии о неизвестных законах распределения строятся по аналогии с параметрическими
- У нас в распоряжении есть выборка, по ней мы оценили эмпирическую функцию распределения  $\hat{F}_n(x)$
- Надо понять насколько она отличается от  $F_0(x)$ , то есть надо посчитать расстояние между функциями и узнать его распределение

# Расстояние между функциями

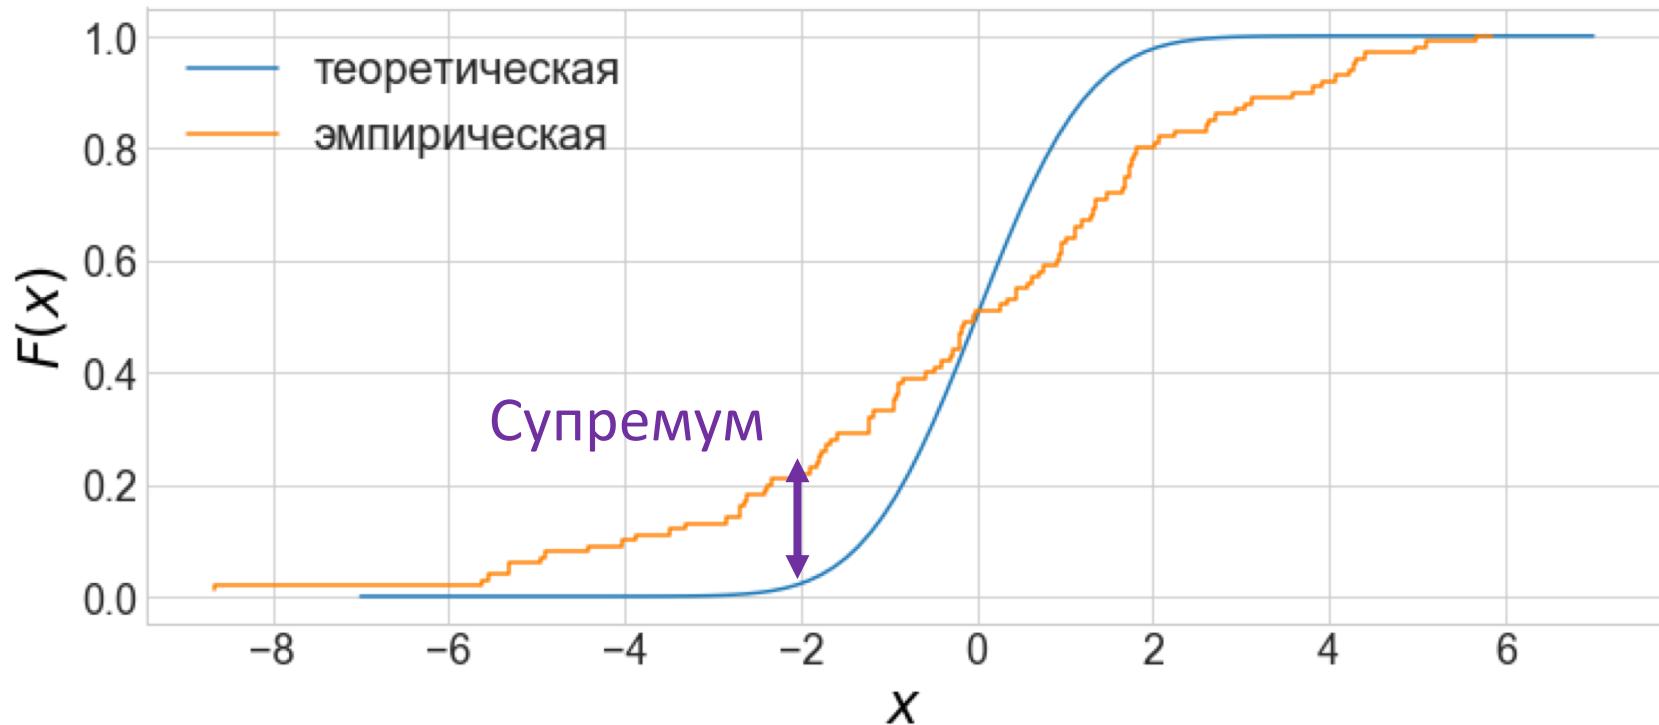
- Как измерить расстояние между двумя функциями?
- Разные способы сделать это  $\Rightarrow$  разные критерии



# Критерий Колмогорова

- Можно найти между ними самое большое расстояние:

$$D_n(X_1, \dots, X_n) = \sup_x |F_0(x) - \hat{F}_n(x)|$$



# Теорема Колмогорова

Статистика Колмогорова:

$$D_n(X_1, \dots, X_n) = \sup_x | F_0(x) - \hat{F}_n(x) |$$

# Теорема Колмогорова

Статистика Колмогорова:

$$D_n(X_1, \dots, X_n) = \sup_x |F_0(x) - \hat{F}_n(x)|$$

При справедливости нулевой гипотезы, распределение статистики  $D_n$  одинаково для любых **непрерывных** распределений, при этом его функция распределения:

$$\lim_{n \rightarrow \infty} \mathbb{P}(\sqrt{n} \cdot D_n \leq z) = 1 + 2 \sum_{k=1}^{\infty} (-1)^k e^{-2k^2 z^2}$$

# Теорема Колмогорова

Статистика Колмогорова:

$$D_n(X_1, \dots, X_n) = \sup_x |F_0(x) - \hat{F}_n(x)|$$

При справедливости нулевой гипотезы, распределение статистики  $D_n$  одинаково для любых **непрерывных** распределений, при этом его функция распределения:

$$\lim_{n \rightarrow \infty} \mathbb{P}(\sqrt{n} \cdot D_n \leq z) = 1 + 2 \sum_{k=1}^{\infty} (-1)^k e^{-2k^2z^2}$$



Распределение Колмогорова –  
наш новый союзник, на её основе  
мы можем построить критерий

# Критерий Колмогорова

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

$H_a: F_X(x) \neq F_0(x)$

# Критерий Колмогорова

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

$H_a: F_X(x) \neq F_0(x)$

**Критерий для проверки:**

$$K_n = \sqrt{n} \cdot \sup_x |F_0(x) - \hat{F}_n(x)|$$

$K_n \underset{H_0}{\overset{asy}{\sim}}$  распределение  
Колмогорова

# Критерий Колмогорова

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

$H_a: F_X(x) \neq F_0(x)$

**Критерий для проверки:**

$$K_n = \sqrt{n} \cdot \sup_x |F_0(x) - \hat{F}_n(x)|$$

$K_n \underset{H_0}{\overset{asy}{\sim}}$  распределение Колмогорова



$K_{\text{набл.}} > K_{1-\alpha}$



$K_{\text{набл.}} \leq K_{1-\alpha}$

# Критерий Колмогорова

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

$H_a: F_X(x) \neq F_0(x)$

**Критерий для проверки:**

$$K_n = \sqrt{n} \cdot \sup_x |F_0(x) - \hat{F}_n(x)|$$

$K_n \underset{H_0}{\overset{asy}{\sim}}$  распределение Колмогорова



$K_{\text{набл.}} > K_{1-\alpha}$



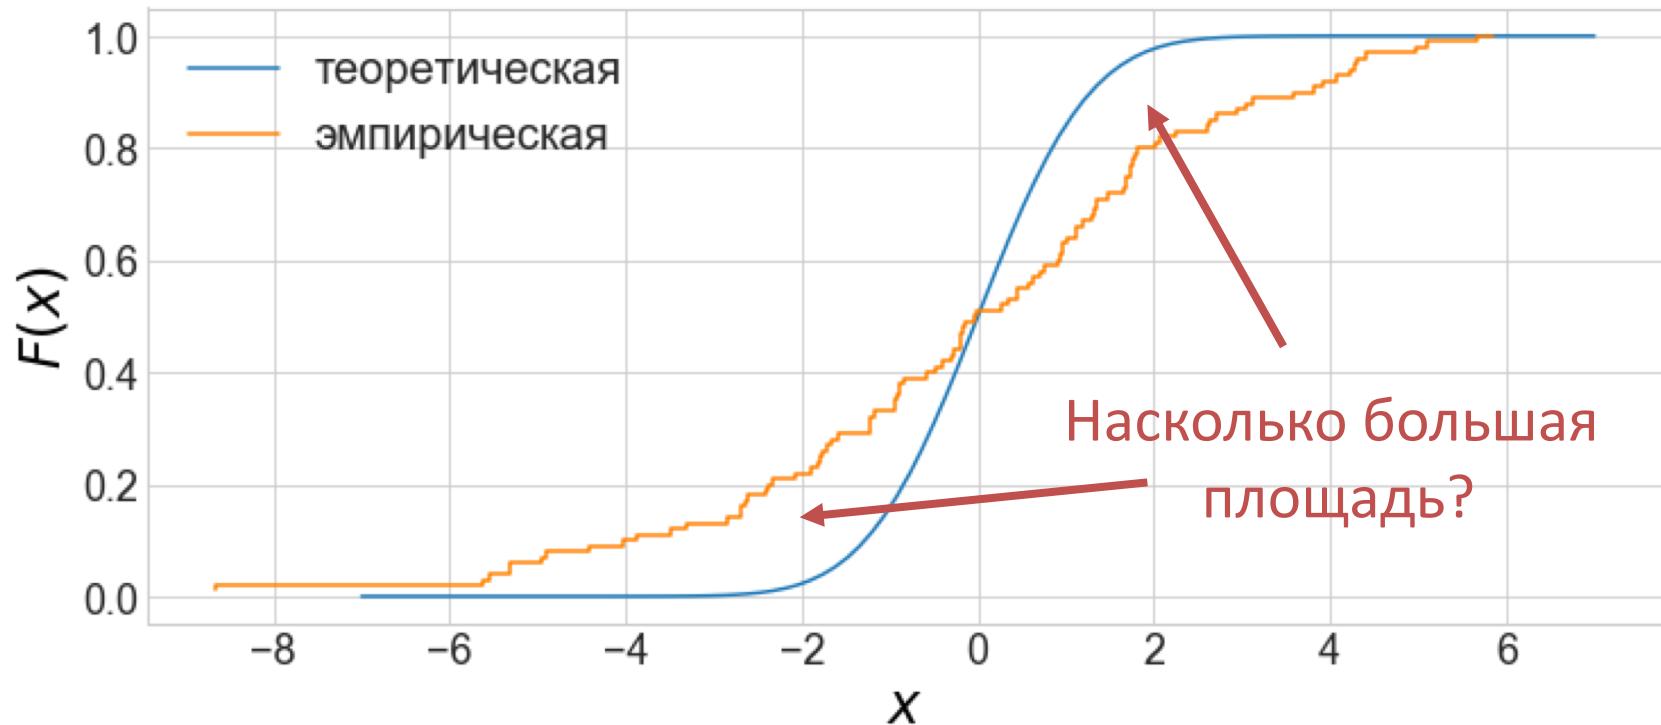
Критерий применяется только для непрерывных распределений



$K_{\text{набл.}} \leq K_{1-\alpha}$

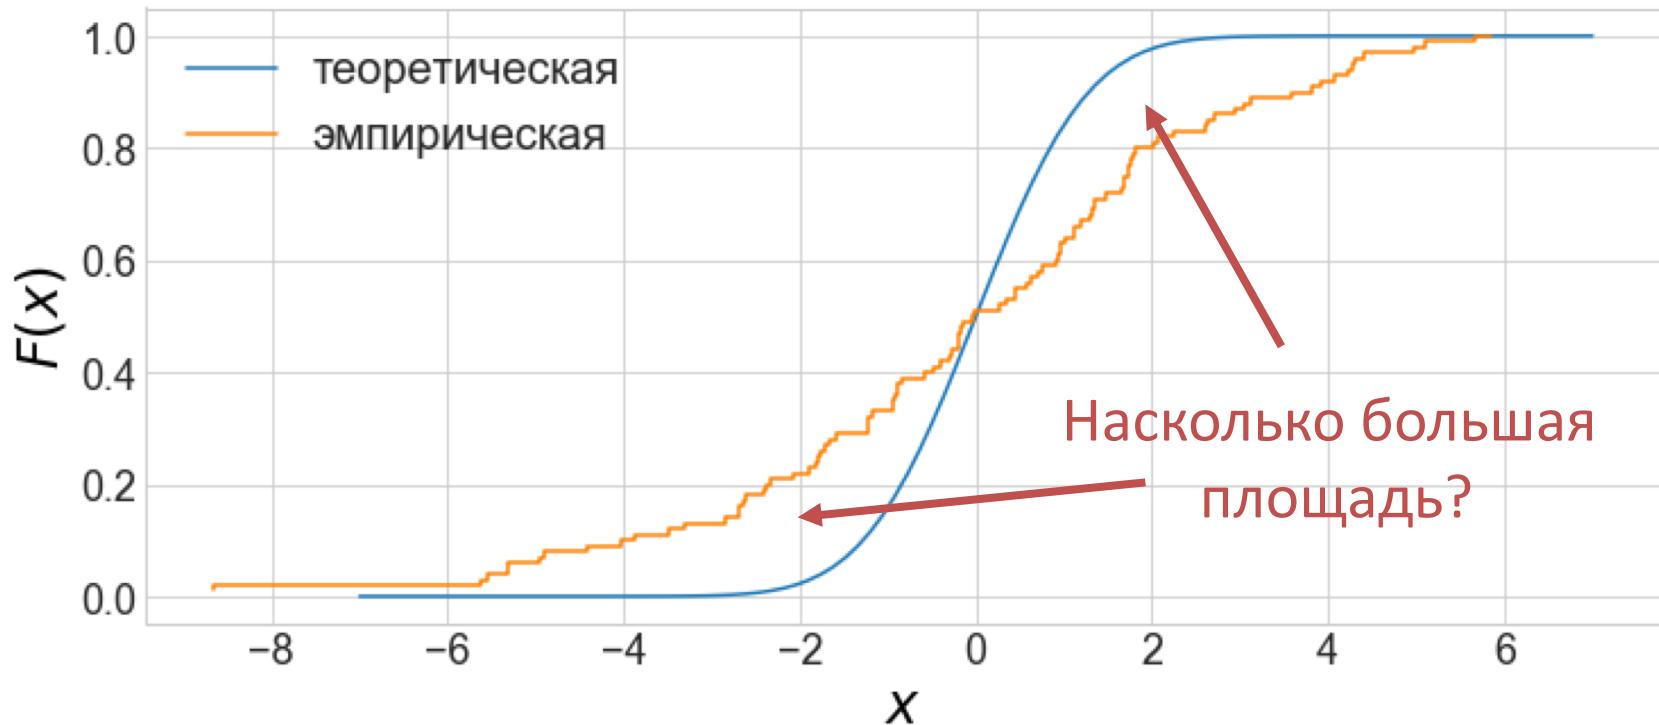
- Критические значения рассчитываются по таблицам, составленным для распределения Колмогорова

# Другие способы искать расстояние



# Другие способы искать расстояние

$$\int_{-\infty}^{+\infty} \psi(F_0(x)) \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

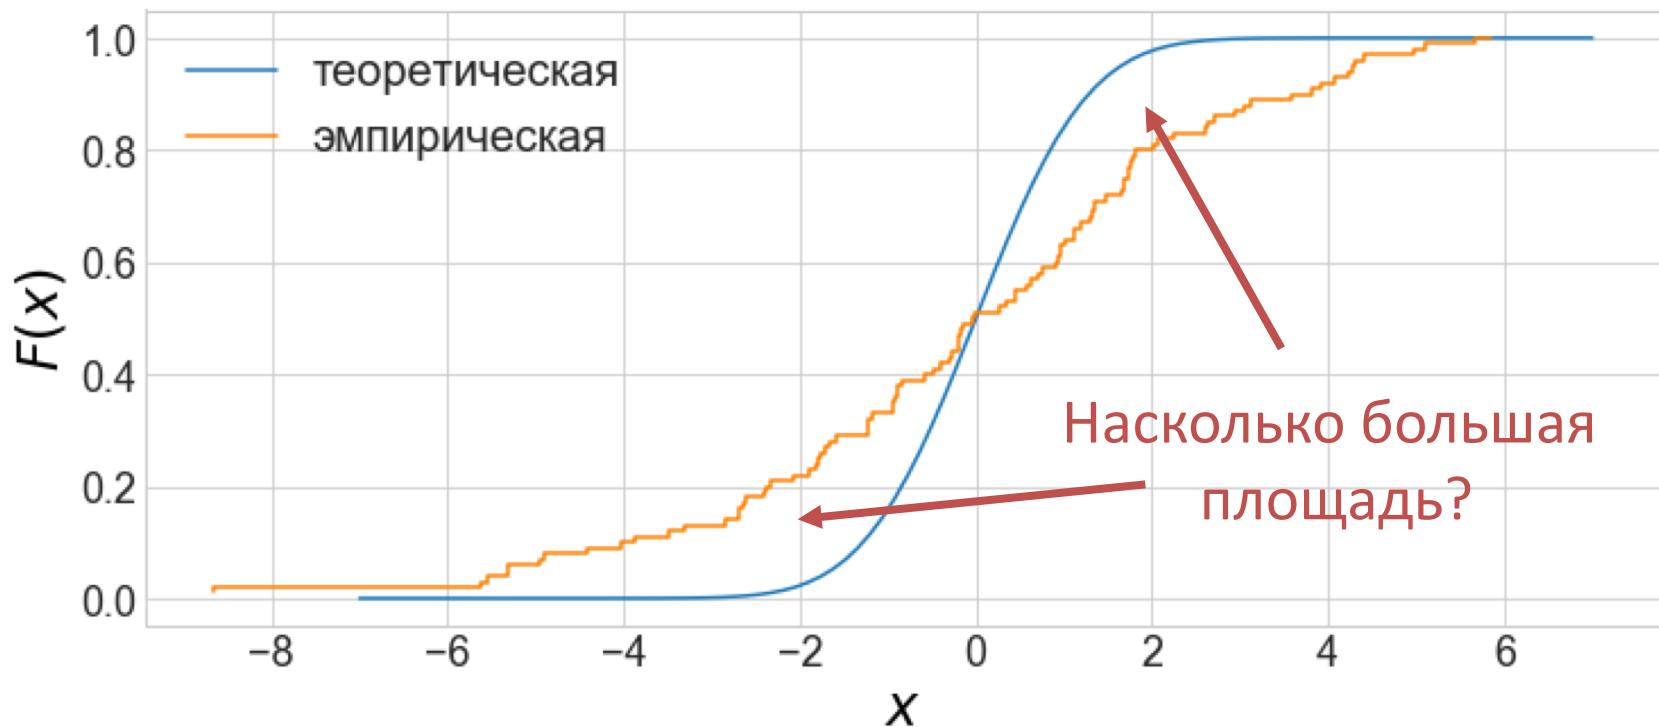


# Другие способы искать расстояние

$$\int_{-\infty}^{+\infty} \psi(F_0(x)) \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$



чем больше разница,  
тем выше штраф

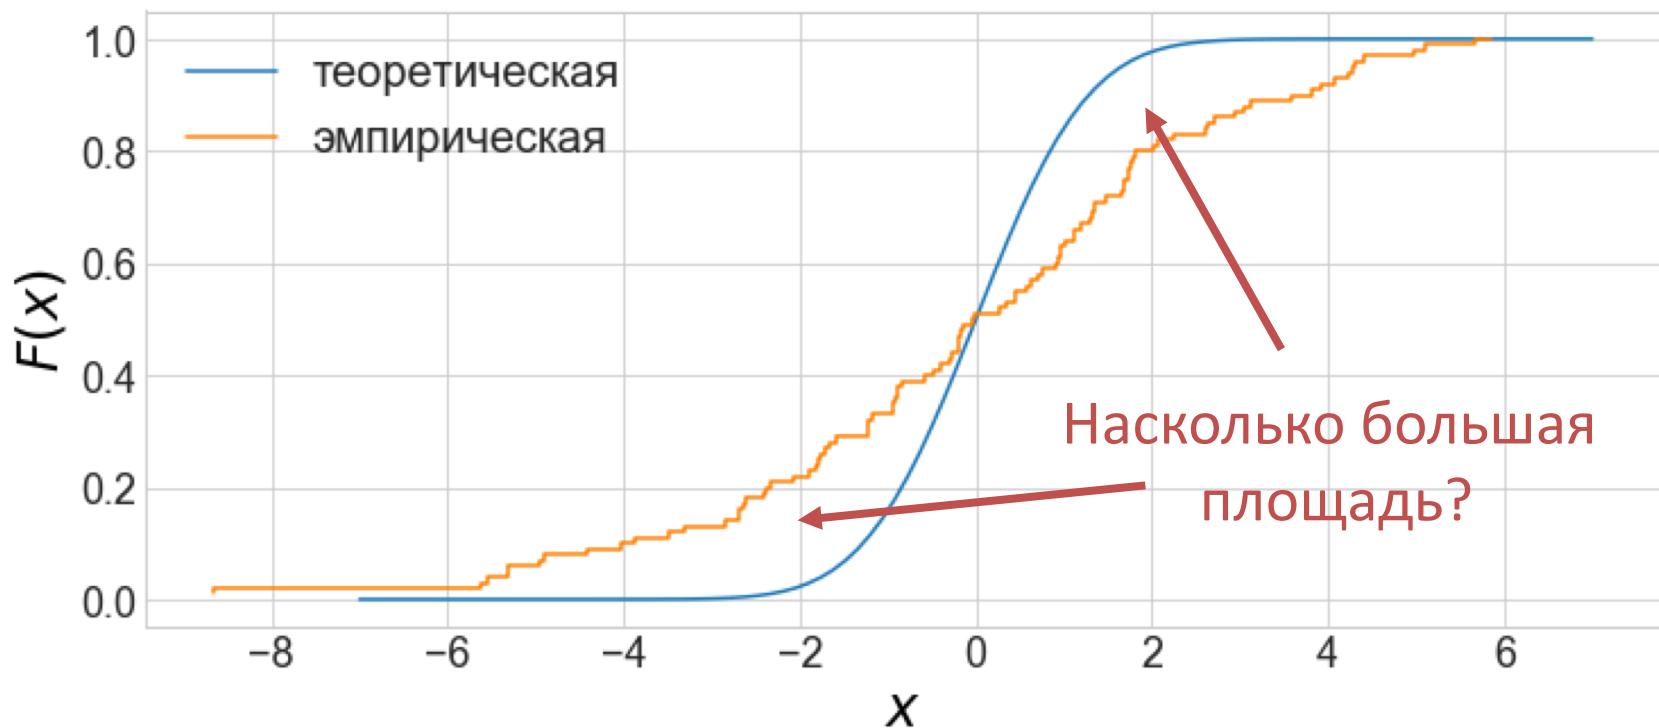


# Другие способы искать расстояние

$$\int_{-\infty}^{+\infty} \psi(F_0(x)) \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

усредняем по распределению

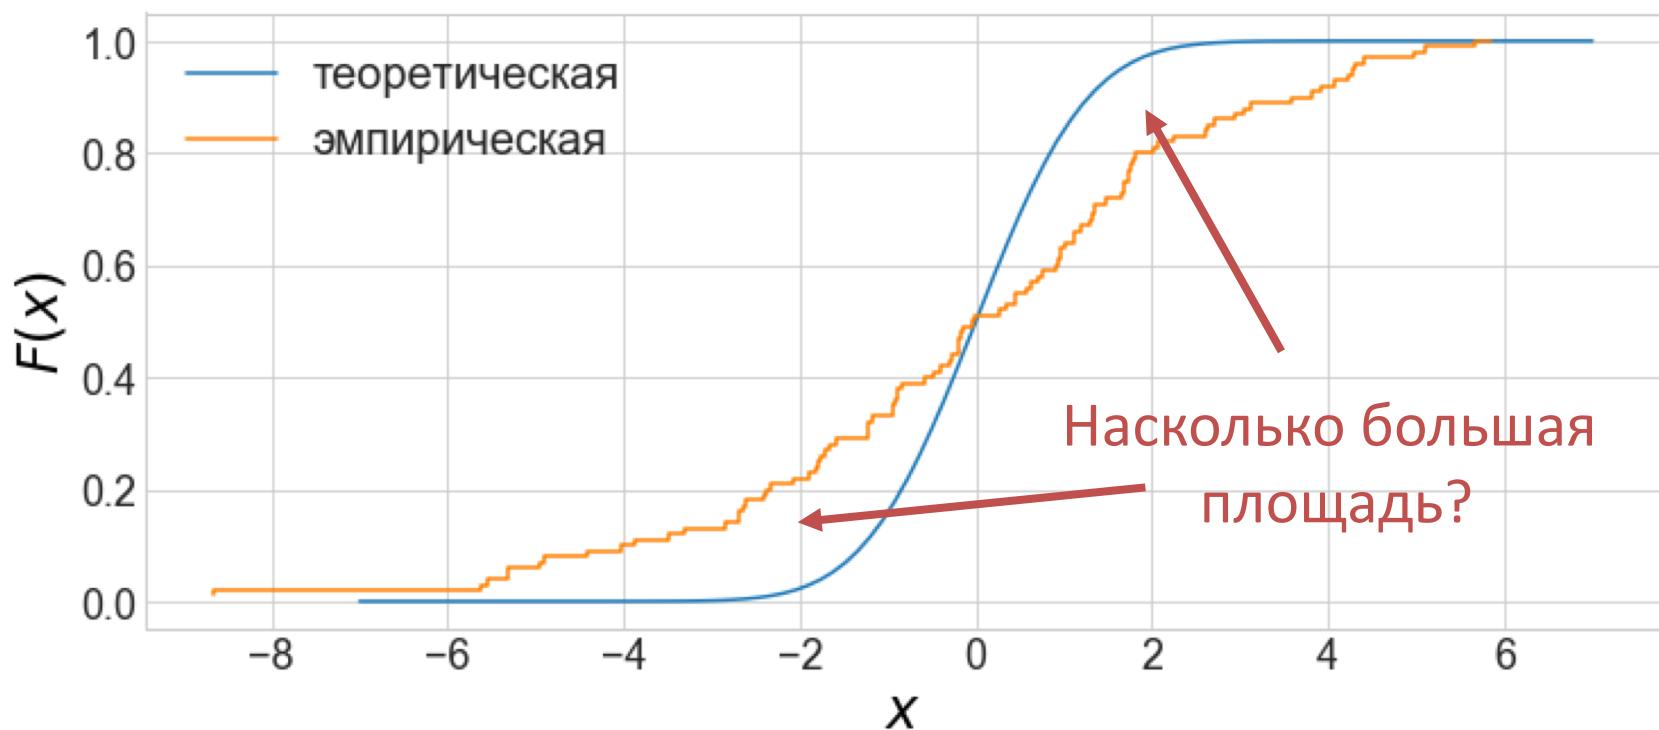
чем больше разница, тем выше штраф



# Другие способы искать расстояние

$$\int_{-\infty}^{+\infty} \psi(F_0(x)) \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

функция - вес  
усредняем по распределению  
чем больше разница,  
тем выше штраф



# Критерий Крамера-Мизеса

$$\int_{-\infty}^{+\infty} 1 \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

- Чем больше разница между функциями, тем выше штраф
- Разница усредняется по всем возможным значениям случайной величины
- Хорошо улавливает разницу в области “типовых значений” случайной величины

# Критерий Андерсона-Дарлинга

$$\int_{-\infty}^{+\infty} \frac{1}{F_0(x)(1 - F_0(x))} \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

- При  $F_0(x) \rightarrow 1$  или  $F_0(x) \rightarrow 0$  дополнительный множитель оказывается очень большим

# Критерий Андерсона-Дарлинга

$$\int_{-\infty}^{+\infty} \frac{1}{F_0(x)(1 - F_0(x))} \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

- При  $F_0(x) \rightarrow 1$  или  $F_0(x) \rightarrow 0$  дополнительный множитель оказывается очень большим
- Получается, что основное внимание уделяется разнице “на хвостах” распределения

# Критерий Андерсона-Дарлинга

$$\int_{-\infty}^{+\infty} \frac{1}{F_0(x)(1 - F_0(x))} \cdot [F_0(x) - \hat{F}_n(x)]^2 \cdot f_0(x) dx$$

- При  $F_0(x) \rightarrow 1$  или  $F_0(x) \rightarrow 0$  дополнительный множитель оказывается очень большим
- Получается, что основное внимание уделяется разнице “на хвостах” распределения
- Для подобных критериев также известны предельные распределения, которыми можно пользоваться для проверки гипотез

# Гипотезы об однородности выборок

$$X_1, \dots, X_{n_x} \sim iid F_X(x)$$

$$Y_1, \dots, Y_{n_y} \sim iid F_Y(x)$$

# Гипотезы об однородности выборок

$$X_1, \dots, X_{n_x} \sim iid F_X(x) \quad Y_1, \dots, Y_{n_y} \sim iid F_Y(x)$$

- Гипотезы о том, что выборки сделаны из одного и того же распределения

$$H_0: F_X(x) = F_Y(x)$$

$$H_a: F_X(x) \neq F_Y(x)$$

# Гипотезы об однородности выборок

$$X_1, \dots, X_{n_x} \sim iid F_X(x)$$

$$Y_1, \dots, Y_{n_y} \sim iid F_Y(x)$$

- Гипотезы о том, что выборки сделаны из одного и того же распределения

$$H_0: F_X(x) = F_Y(x)$$

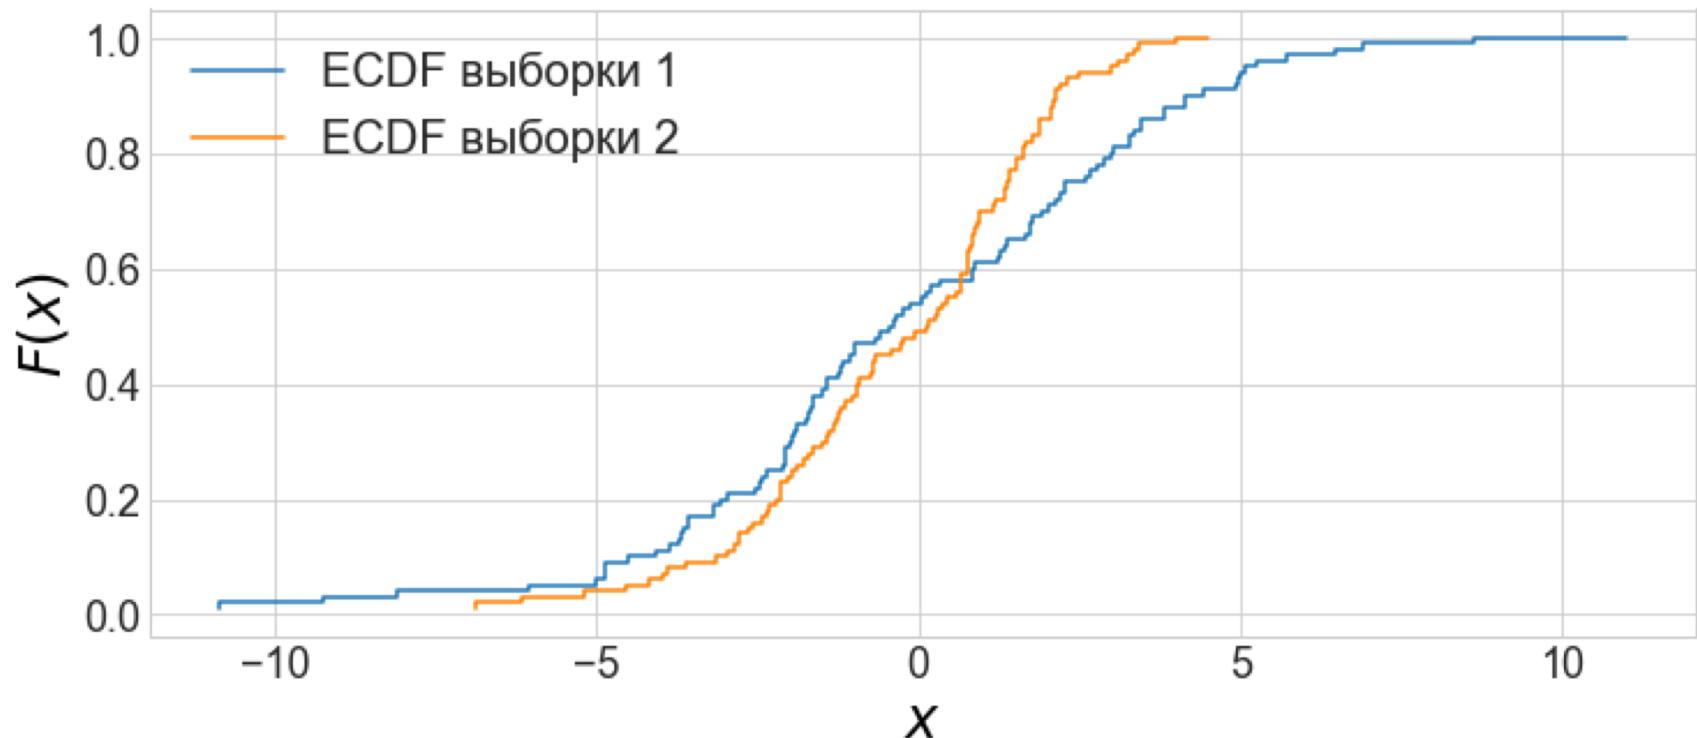
$$H_a: F_X(x) \neq F_Y(x)$$

- Для проверки этой гипотезы можно использовать ту же самую идею, но расстояние надо будет считать между эмпирическими функциями распределения

# Критерий Колмогорова-Смирнова

Снова будем искать супремум, но уже между эмпирическими функциями

$$D_n = \sup_x | \hat{F}_X(x) - \hat{F}_Y(x) |$$



# Критерий Колмогорова-Смирнова

Снова будем искать супремум, но уже между эмпирическими функциями

$$D_n = \sup_x | \hat{F}_X(x) - \hat{F}_Y(x) |$$

- Статистика

$$\sqrt{\frac{n_x \cdot n_y}{n_x + n_y}} \cdot D_n$$

при  $n_x, n_y \rightarrow \infty$  имеет распределение Колмогорова

- Она используется для проверки гипотезы об однородности выборок

# Резюме

- Чтобы проверять гипотезы о распределениях, нужно научиться считать между ними расстояния

# Резюме

- Чтобы проверять гипотезы о распределениях, нужно научиться считать между ними расстояния
- Критерий Колмогорова ищет расстояние как супремум и позволяет проверять гипотезы о распределении и однородности выборок

# Резюме

- Чтобы проверять гипотезы о распределениях, нужно научиться считать между ними расстояния
- Критерий Колмогорова ищет расстояние как супремум и позволяет проверять гипотезы о распределении и однородности выборок
- Критерии Крамера-Мизеса и Андерсона-Дарлинга помогают специфицировать критерий либо для "средиземья" либо для "крайнеземья" (хвостов)

# Резюме

- Эти критерии работают только для непрерывных распределений

# Резюме

- Эти критерии работают только для непрерывных распределений
- Неизвестные параметры распределения фиксируются в нулевой гипотезе

# Резюме

- Эти критерии работают только для непрерывных распределений
- Неизвестные параметры распределения фиксируются в нулевой гипотезе
- Если мы оцениваем параметры по выборке, распределения Колмогорова не будет одинаковым для всех распределений
- Для различных распределений можно строить уточнения теста Колмогорова

# Критерий Пирсона

# Критерий Пирсона

- Критерий Колмогорова работает только для непрерывных распределений

# Критерий Пирсона

- Критерий Колмогорова работает только для непрерывных распределений
- Для проверки гипотез о дискретных распределениях используется критерий Пирсона

$$H_0: F_X(x) = F_0(x)$$

$$H_a: F_X(x) \neq F_0(x)$$

# Критерий Пирсона

- Критерий Колмогорова работает только для непрерывных распределений
- Для проверки гипотез о дискретных распределениях используется критерий Пирсона

$$H_0: F_X(x) = F_0(x)$$

$$H_a: F_X(x) \neq F_0(x)$$

- Критерий Пирсона считает расстояние между распределениями с помощью сверки теоретических и эмпирических частот между собой

# Критерий Пирсона

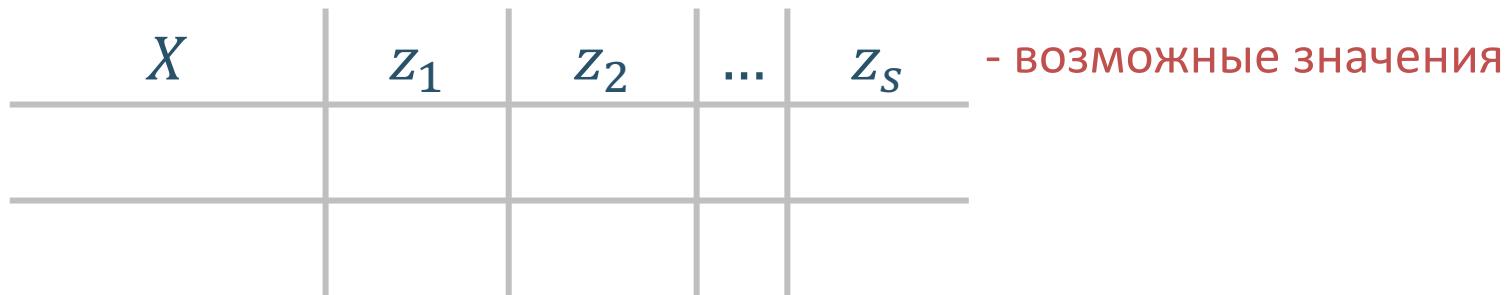
- Выборка  $X_1, \dots, X_n$  из дискретного распределения

# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями

# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями



# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями

$X$	$z_1$	$z_2$	$\dots$	$z_s$	- возможные значения
$\mathbb{P}(X = z)$	$p_1(\theta)$	$p_2(\theta)$	$\dots$	$p_s(\theta)$	- теоретические вероятности

# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями

$X$	$z_1$	$z_2$	$\dots$	$z_s$	- возможные значения
$\mathbb{P}(X = z)$	$p_1(\theta)$	$p_2(\theta)$	$\dots$	$p_s(\theta)$	- теоретические вероятности
$\#(X_i = z)$	$v_1$	$v_2$	$\dots$	$v_s$	- эмпирические частоты

# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями

$X$	$z_1$	$z_2$	$\dots$	$z_s$	- возможные значения
$\mathbb{P}(X = z)$	$p_1(\theta)$	$p_2(\theta)$	$\dots$	$p_s(\theta)$	- теоретические вероятности
$\#(X_i = z)$	$\nu_1$	$\nu_2$	$\dots$	$\nu_s$	- эмпирические частоты

- Нужно сравнить все эмпирические частоты с теоретическими

# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями

$X$	$z_1$	$z_2$	$\dots$	$z_s$	- возможные значения
$\mathbb{P}(X = z)$	$p_1(\theta)$	$p_2(\theta)$	$\dots$	$p_s(\theta)$	- теоретические вероятности
$\#(X_i = z)$	$v_1$	$v_2$	$\dots$	$v_s$	- эмпирические частоты

- Нужно сравнить все эмпирические частоты с теоретическими

$\hat{\theta}$  – состоятельная  
оценка параметров  
распределения

$k$  – их количество

# Критерий Пирсона

- Выборка  $X_1, \dots, X_n$  из дискретного распределения
- Предполагаем, что случайная величина принимает  $s$  значений с какими-то вероятностями

$X$	$z_1$	$z_2$	$\dots$	$z_s$	- возможные значения
$\mathbb{P}(X = z)$	$p_1(\theta)$	$p_2(\theta)$	$\dots$	$p_s(\theta)$	- теоретические вероятности
$\#(X_i = z)$	$v_1$	$v_2$	$\dots$	$v_s$	- эмпирические частоты

- Нужно сравнить все эмпирические частоты с теоретическими
- $\hat{\theta}$  – состоятельная оценка параметров распределения  
 $k$  – их количество

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} \stackrel{\text{asy}}{\underset{H_0}{\sim}} \chi_{s-k-1}^2$$

# Критерий Пирсона

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

$H_a: F_X(x) \neq F_0(x)$

Критерий для проверки:

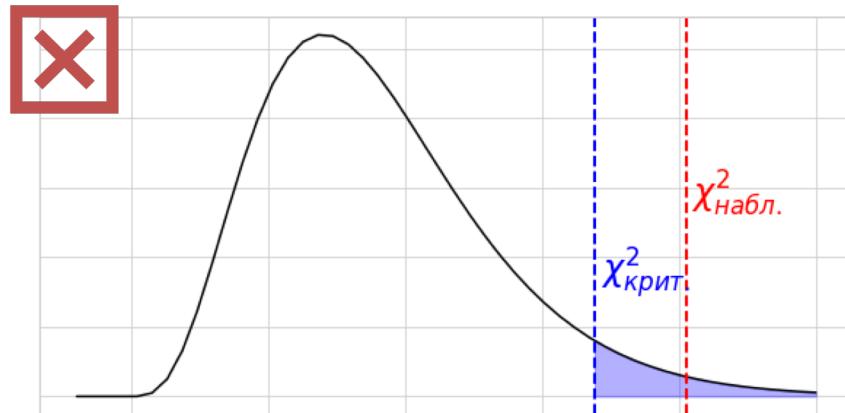
$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} \stackrel{asy}{\underset{H_0}{\sim}} \chi_{s-k-1}^2$$

# Критерий Пирсона

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

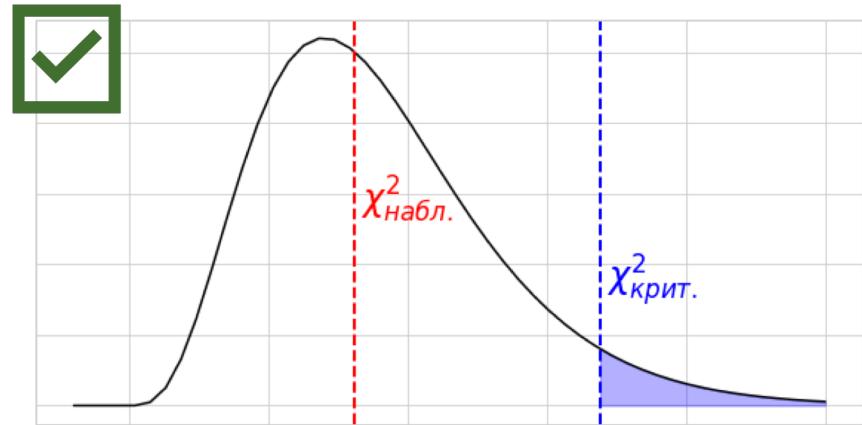
$H_a: F_X(x) \neq F_0(x)$



$$\chi^2_{\text{набл.}} > \chi^2_{s-k-1}(1 - \alpha)$$

Критерий для проверки:

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} \stackrel{asy}{\underset{H_0}{\sim}} \chi^2_{s-k-1}$$



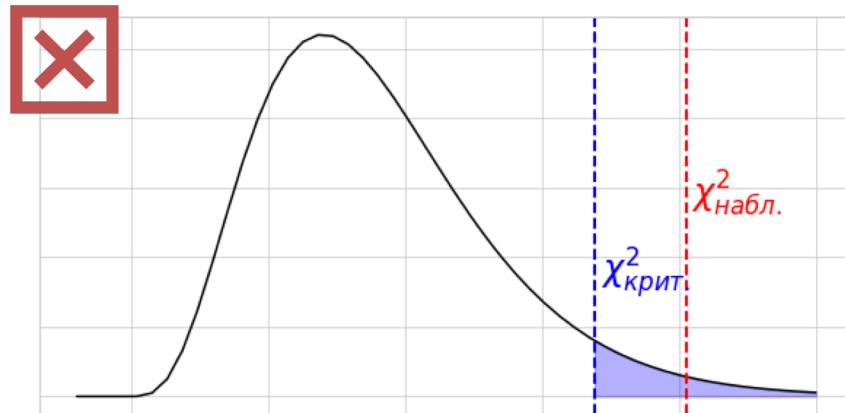
$$\chi^2_{\text{набл.}} \leq \chi^2_{s-k-1}(1 - \alpha)$$

# Критерий Пирсона

$X_1, \dots, X_n \sim iid F_X(x)$

$H_0: F_X(x) = F_0(x)$

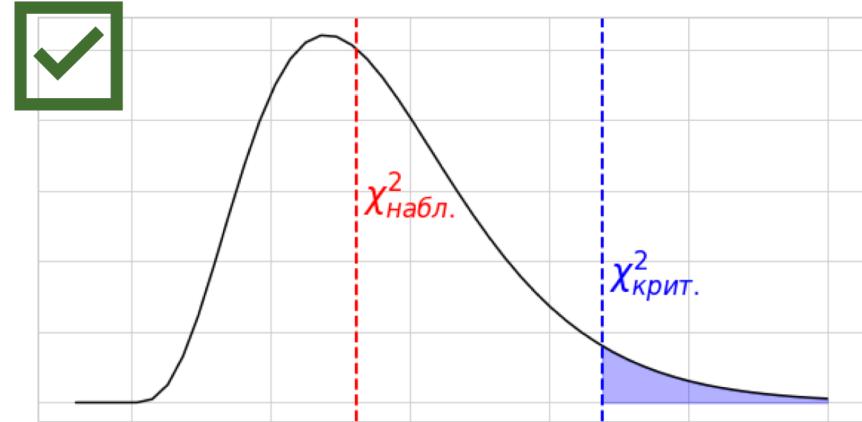
$H_a: F_X(x) \neq F_0(x)$



$$\chi^2_{\text{набл.}} > \chi^2_{s-k-1}(1 - \alpha)$$

Критерий для проверки:

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} \stackrel{asy}{\underset{H_0}{\sim}} \chi^2_{s-k-1}$$



$$\chi^2_{\text{набл.}} \leq \chi^2_{s-k-1}(1 - \alpha)$$

! Критерий обычно применяют для дискретных распределений

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	?	?	?	?	?	?	?	?
$\#(x_i = z)$	199	170	87	31	9	2	1	1

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	?	?	?	?	?	?	?	?
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda)$$

$$\mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	?	?	?	?	?	?	?
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda) \quad \hat{\lambda} = \bar{x} \approx 1 - \text{состоятельная оценка}$$

$$\mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

$$\mathbb{P}(X = 0) = \frac{e^{-1} 1^0}{0!} = 0.37$$

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	0.37	?	?	?	?	?	?
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda)$$

$\hat{\lambda} = \bar{x} \approx 1$  – состоятельная оценка

$$\mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

$$\mathbb{P}(X = 0) = \frac{e^{-1} 1^0}{0!} = 0.37$$

$$\mathbb{P}(X = 1) = \frac{e^{-1} 1^1}{1!} = 0.37$$

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

вместе, т.к. их мало

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	0.37	0.18	0.06		0.02		
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda)$$

$\hat{\lambda} = \bar{x} \approx 1$  – состоятельная оценка

$$\mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

$$\mathbb{P}(X = 0) = \frac{e^{-1} 1^0}{0!} = 0.37$$

$$\mathbb{P}(X = 1) = \frac{e^{-1} 1^1}{1!} = 0.37$$

...

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

вместе, т.к. их мало

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	0.37	0.18	0.06			0.02	
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda)$$

$$\hat{\lambda} = \bar{x} \approx 1 - \text{состоятельная оценка}$$

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} = \frac{(199 - 500 \cdot 0.37)^2}{500 \cdot 0.37} + \dots$$

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

вместе, т.к. их мало

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	0.37	0.18	0.06			0.02	
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda) \quad \hat{\lambda} = \bar{x} \approx 1 - \text{состоятельная оценка}$$

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} = \frac{(199 - 500 \cdot 0.37)^2}{500 \cdot 0.37} + \dots = 3.85$$

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

вместе, т.к. их мало

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	0.37	0.18	0.06			0.02	
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda) \quad \hat{\lambda} = \bar{x} \approx 1 - \text{состоятельная оценка}$$

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} = \frac{(199 - 500 \cdot 0.37)^2}{500 \cdot 0.37} + \dots = 3.85$$

$$\chi^2_{s-k-1}(1-\alpha) = \chi^2_{5-1-1}(1-0.05) = \chi^2_3(0.95) = 7.8$$

## Пример:

- $X$  – Количество сделок на фондовой бирже за квартал для пятисот инвесторов

вместе, т.к. их мало

$X$	0	1	2	3	4	5	6	7
$\mathbb{P}(X = z)$	0.37	0.37	0.18	0.06			0.02	
$\#(x_i = z)$	199	170	87	31	9	2	1	1

$$H_0: X \sim Poiss(\lambda) \quad \hat{\lambda} = \bar{x} \approx 1 - \text{состоятельная оценка}$$

$$\sum_{j=1}^s \frac{(v_j - n \cdot p_j(\hat{\theta}))^2}{n \cdot p_j(\hat{\theta})} = \frac{(199 - 500 \cdot 0.37)^2}{500 \cdot 0.37} + \dots = 3.85$$

$$\chi^2_{s-k-1}(1-\alpha) = \chi^2_{5-1-1}(1-0.05) = \chi^2_3(0.95) = 7.8$$



Гипотеза о распределении Пуассона **не отвергается**

# Критерий Пирсона

- Критерий Пирсона не состоятелен против всех альтернатив, т.е. бывают распределения, которые он не может отличить друг от друга

# Критерий Пирсона

- Критерий Пирсона не состоятелен против всех альтернатив, т.е. бывают распределения, которые он не может отличить друг от друга
- Можно попробовать использовать критерий Пирсона для непрерывных распределений

# Критерий Пирсона

- Критерий Пирсона не состоятелен против всех альтернатив, т.е. бывают распределения, которые он не может отличить друг от друга
- Можно попробовать использовать критерий Пирсона для непрерывных распределений
- Для этого нужно будет разбить все возможные значения непрерывной случайной величины на бины (как на гистограмме)

# Критерий Пирсона

- Критерий Пирсона не состоятелен против всех альтернатив, т.е. бывают распределения, которые он не может отличить друг от друга
- Можно попробовать использовать критерий Пирсона для непрерывных распределений
- Для этого нужно будет разбить все возможные значения непрерывной случайной величины на бины (как на гистограмме)
- Результат работы теста будет зависеть от числа выбранных бинов  $\Rightarrow$  лучше пользоваться для непрерывных распределений другими критериями

# Гипотезы об однородности выборок

- Критерий Пирсона по аналогии с критерием Колмогорова можно использовать для проверки гипотез об однородности выборок

$$X_1, \dots, X_{n_x} \sim iid F_X(x) \quad Y_1, \dots, Y_{n_y} \sim iid F_Y(x)$$

## Выборки независимые

$$H_0: F_X(x) = F_Y(x)$$

$$H_a: F_X(x) \neq F_Y(x)$$

# Критерий Пирсона

- Нужно сравнивать эмпирические частоты между собой

$X, Y$	$z_1$	$z_2$	$\dots$	$z_s$
$\#(y_i = z)$	$w_1$	$w_2$	$\dots$	$w_s$
$\#(x_i = z)$	$v_1$	$v_2$	$\dots$	$v_s$

# Критерий Пирсона

- Нужно сравнивать эмпирические частоты между собой

$X, Y$	$z_1$	$z_2$	...	$z_s$
$\#(y_i = z)$	$w_1$	$w_2$	...	$w_s$
$\#(x_i = z)$	$v_1$	$v_2$	...	$v_s$

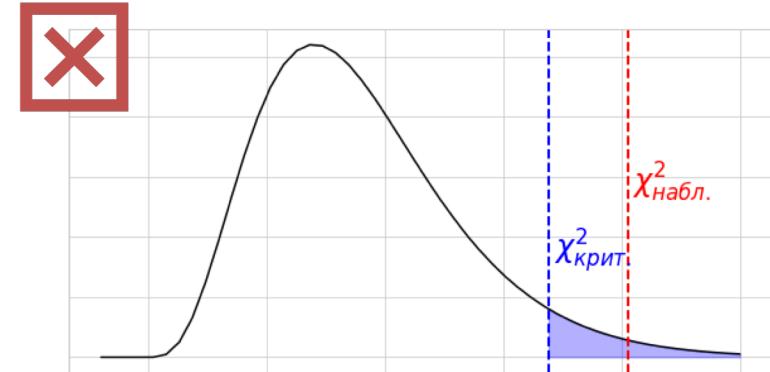
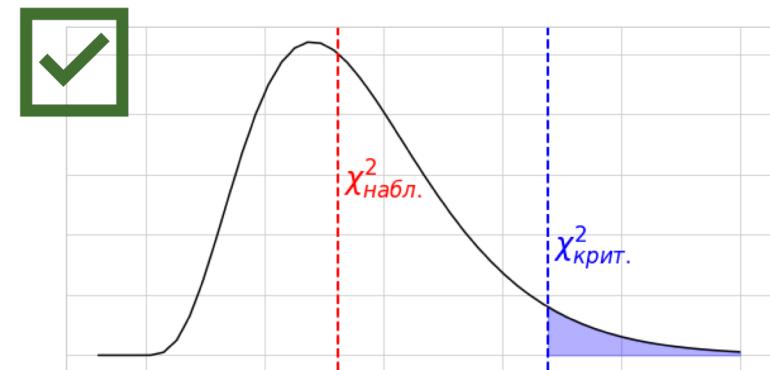
$$\sum_{j=1}^s \frac{\left(\frac{v_j}{n_x} - \frac{w_j}{n_y}\right)^2}{n_x + n_y} \stackrel{\text{asy}}{\underset{H_0}{\sim}} \chi_{s-1}^2$$

# Критерий Пирсона

- Нужно сравнивать эмпирические частоты между собой

$X, Y$	$z_1$	$z_2$	...	$z_s$
$\#(y_i = z)$	$w_1$	$w_2$	...	$w_s$
$\#(x_i = z)$	$v_1$	$v_2$	...	$v_s$

$$\sum_{j=1}^s \frac{\left(\frac{v_j}{n_x} - \frac{w_j}{n_y}\right)^2}{n_x + n_y} \stackrel{\text{asy}}{\underset{H_0}{\sim}} \chi^2_{s-1}$$

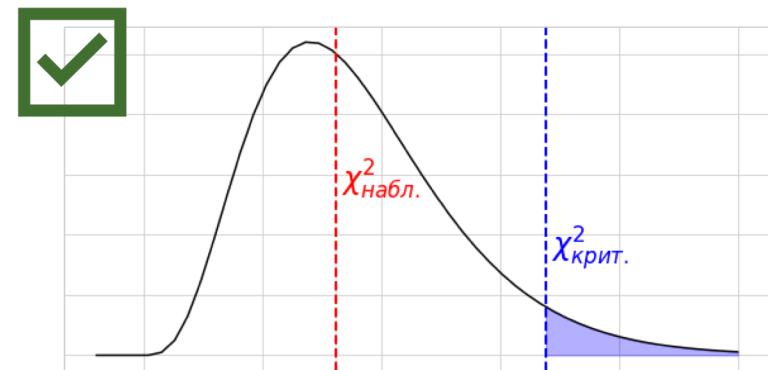


# Критерий Пирсона

- Нужно сравнивать эмпирические частоты между собой

$X, Y$	$z_1$	$z_2$	...	$z_s$
$\#(y_i = z)$	$w_1$	$w_2$	...	$w_s$
$\#(x_i = z)$	$v_1$	$v_2$	...	$v_s$

$$\sum_{j=1}^s \frac{\left(\frac{v_j}{n_x} - \frac{w_j}{n_y}\right)^2}{\frac{n_x + n_y}{n_x}} \stackrel{\text{asy}}{\underset{H_0}{\sim}} \chi^2_{s-1}$$



- Можно использовать критерий для непрерывных распределений, но тогда придется дробить данные на бины

# Резюме

- Критерий Пирсона позволяет проверять гипотезы о виде распределения для дискретных случайных величин
- Его можно использовать и для непрерывных величин, но результат будет зависеть от числа выбранных групп